Estadística bidimensional

Nombre: _____ Fecha: _____

Qué vas a aprender

- Organizar datos de dos variables en tablas y representarlos en una nube de puntos
- Describir de forma cualitativa la correlación entre dos variables
- Calcular la covarianza y el coeficiente de correlación de Pearson
- Obtener las rectas de regresión y usarlas para hacer estimaciones
- Valorar la fiabilidad de las estimaciones y distinguir correlación de causalidad
- Usar la calculadora y la hoja de cálculo para estudiar datos bidimensionales

Para pensar

Si en los países donde se consume más chocolate hay más premios Nobel por habitante, ¿comer chocolate hace más inteligente?

Explicación

13.1 Variables estadísticas bidimensionales

Cuando en cada individuo de una población se estudian a la vez **dos caracteres** X e Y, se obtiene una **variable estadística bidimensional** (X, Y). Cada dato es un par de valores (x_i, y_i). Por ejemplo, para cada alumno de un grupo se anotan las horas de estudio semanales (X) y la nota del examen (Y).

Los datos se pueden organizar de dos maneras:

- **Tabla simple**, en dos filas o columnas, cuando hay pocos datos. Es la que usaremos como ejemplo durante el tema:

Horas (x_i)	2	3	4	5	6	7	8	9
Nota (y_i)	4	5	5	6	7	7	8	9

- **Tabla de doble entrada**, cuando hay muchos datos y los valores se repiten: en las filas se ponen los valores de X, en las columnas los de Y y en cada casilla la frecuencia n_{ij} con que aparece cada par. Sumando por filas o columnas se obtienen las **distribuciones marginales** de cada variable.

Cada variable por separado se estudia como en cursos anteriores, con su media y su desviación típica. Lo nuevo es estudiar la **relación** entre las dos: si cuando una aumenta la otra tiende a aumentar o a disminuir, y con qué intensidad. En ciencias experimentales, la variable que se controla (X) se llama **independiente** o explicativa, y la que se mide (Y), **dependiente** o respuesta.

Alumno	Horas	Nota
A	2	4
B	4	5
C	6	7
D	8	8
…	…	…

13.2 La nube de puntos

La representación gráfica de una variable bidimensional es el **diagrama de dispersión** o **nube de puntos**: cada par (x_i, y_i) se dibuja como un punto en unos ejes cartesianos. Si un par se repite, se indica con un punto más grueso o con su frecuencia al lado.

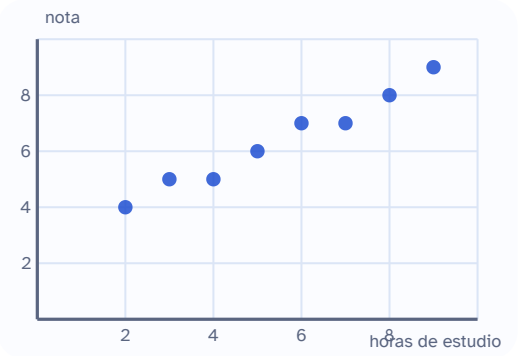
La nube permite ver de un vistazo si hay relación entre las variables y de qué tipo. En el ejemplo de las horas de estudio, los puntos se agrupan en torno a una recta creciente: a más horas, mejor nota, en general.

Al mirar una nube conviene fijarse en tres cosas:

- La **forma**: ¿los puntos se agrupan en torno a una recta, a una curva o no siguen ningún patrón?
- El **sentido**: ¿la tendencia es creciente o decreciente?
- La **intensidad**: ¿los puntos están muy pegados a la línea de tendencia o muy dispersos?

También hay que buscar **valores atípicos**: puntos muy alejados del resto, que pueden deberse a un error de medida o a un caso especial y que influyen mucho en los cálculos. Por ejemplo, un alumno que estudió 9 horas y sacó un 2 porque estaba enfermo el día del examen. Antes de calcular nada, hay que decidir, de forma justificada, si se incluye o no.

Las nubes de puntos son la forma más honesta de presentar datos bidimensionales: un solo número puede esconder una forma rara que el dibujo revela enseguida.



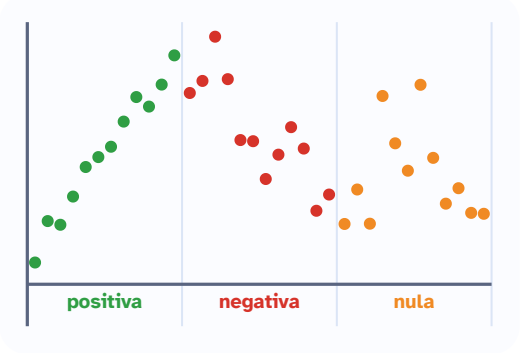
13.3 Tipos de correlación

La **correlación** es la relación estadística entre dos variables. Según la nube de puntos, se clasifica así:

- **Correlación positiva o directa**: al aumentar una variable, la otra tiende a aumentar. La nube es creciente (estatura y peso, horas de estudio y nota).
- **Correlación negativa o inversa**: al aumentar una, la otra tiende a disminuir. La nube es decreciente (altitud y temperatura, precio y número de ventas).
- **Correlación nula o incorrelación**: no se aprecia relación; la nube es una mancha sin forma (estatura y nota de matemáticas).

Según la intensidad, la correlación es **fuerte** si los puntos están muy próximos a una recta y **débil** si están muy dispersos. En el caso extremo de que todos los puntos estén exactamente sobre una recta, hay una **dependencia funcional** lineal: una variable se calcula exactamente a partir de la otra, como el precio de la gasolina y los litros que se echan.

Es importante saber que lo que estudiamos en este tema es la correlación **lineal**. Dos variables pueden estar muy relacionadas aunque la nube no se parezca a una recta: la altura de un objeto lanzado frente al tiempo sigue una parábola. En esos casos el coeficiente de correlación lineal puede ser pequeño aunque la relación sea fuerte, y hay que buscar otro modelo.



13.4 Centro de gravedad y covarianza

El **centro de gravedad** de la nube es el punto $(\bar{x}, \bar{y})$, cuyas coordenadas son las medias de cada variable. En el ejemplo: $\bar{x} = 44/8 = 5{,}5$ horas e $\bar{y} = 51/8 = 6{,}375$ puntos.

Las rectas $x = \bar{x}$ e $y = \bar{y}$ dividen el plano en cuatro cuadrantes. Si la correlación es positiva, la mayoría de los puntos están en el primer cuadrante (los dos por encima de la media) y en el tercero (los dos por debajo); en ellos, el producto $(x_i - \bar{x})(y_i - \bar{y})$ es positivo. Si la correlación es negativa, predominan los cuadrantes

segundo y cuarto, donde el producto es negativo. Esta idea da lugar a la **covarianza**:

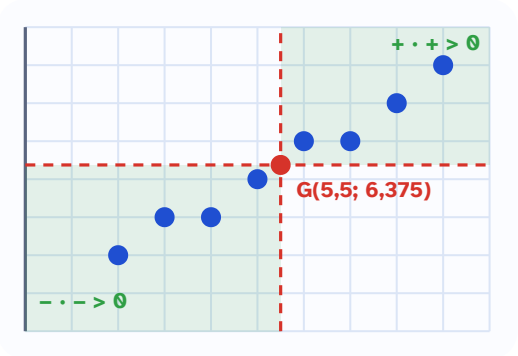
$$\sigma_{xy} = (1/n)\,\Sigma\,(x_i - \bar{x})(y_i - \bar{y}) = (\Sigma\, x_i\, y_i)/n - \bar{x}\cdot\bar{y}$$

La segunda fórmula es la más cómoda para calcular. En el ejemplo, $\Sigma\, x_i y_i = 2{\cdot}4 + 3{\cdot}5 + 4{\cdot}5 + 5{\cdot}6 + 6{\cdot}7 + 7{\cdot}7 + 8{\cdot}8 + 9{\cdot}9 = 309$, así que

$$\sigma_{xy} = 309/8 - 5{,}5 \cdot 6{,}375 = 38{,}625 - 35{,}0625 = 3{,}5625$$

Positiva: correlación directa. Si $\sigma_{xy} < 0$ la correlación es inversa y si $\sigma_{xy} \approx 0$, no hay correlación lineal.

El inconveniente de la covarianza es que depende de las **unidades**: si las horas se midieran en minutos, la covarianza se multiplicaría por 60, aunque la relación sea la misma. Por eso no sirve para comparar la intensidad de la relación entre distintos estudios. Con datos en tabla de doble entrada, cada producto se multiplica por su frecuencia: $\sigma_{xy} = (\Sigma\, n_{ij}\, x_i\, y_j)/N - \bar{x}\cdot\bar{y}$.



13.5 El coeficiente de correlación de Pearson

Para medir la intensidad de la relación lineal sin que influyan las unidades, se divide la covarianza entre el producto de las desviaciones típicas. Se obtiene el **coeficiente de correlación lineal de Pearson**:

$$r = \sigma_{xy} / (\sigma_x \cdot \sigma_y)$$

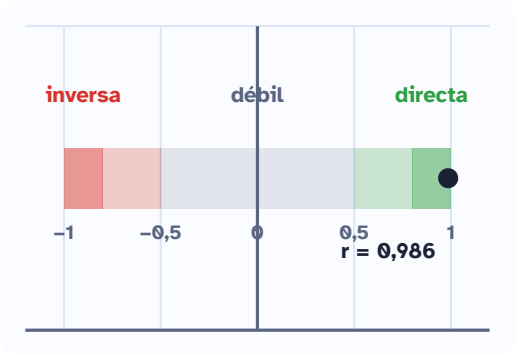
Recuerda que $\sigma_x = \sqrt{(\Sigma\, x_i^2/n - \bar{x}^2)}$. En el ejemplo:

- $\Sigma x_i^2 = 284 \rightarrow \sigma_x^2 = 284/8 - 5{,}5^2 = 5{,}25 \rightarrow \sigma_x \approx 2{,}291$.
- $\Sigma y_i^2 = 345 \rightarrow \sigma_y^2 = 345/8 - 6{,}375^2 \approx 2{,}484 \rightarrow \sigma_y \approx 1{,}576$.
- $r = 3{,}5625/(2{,}291 \cdot 1{,}576) \approx$ **0,986**.

Propiedades de r:

- No tiene unidades y siempre está entre –1 y 1: **$-1 \leq r \leq 1$**.
- Tiene el mismo signo que la covarianza: r > 0 correlación directa; r < 0, inversa.
- Si |r| = 1, todos los puntos están sobre una recta (dependencia funcional).
- Cuanto más cerca está |r| de 1, más fuerte es la correlación; cerca de 0, la correlación lineal es débil o nula.

No hay una frontera exacta, pero de forma orientativa se dice que la correlación es fuerte si |r| ≥ 0,8, moderada entre 0,5 y 0,8 y débil por debajo de 0,5. En el ejemplo, r ≈ 0,986 indica una correlación positiva muy fuerte entre las horas de estudio y la nota.



13.6 Correlación y causalidad

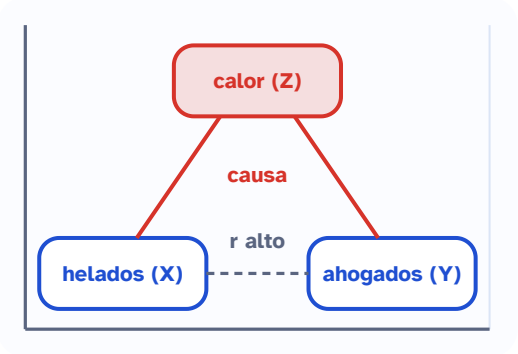
Un coeficiente de correlación alto indica que las dos variables «van juntas», pero **no demuestra que una cause la otra**. Hay varias explicaciones posibles para una correlación:

- **Causa directa**: X provoca Y. La dosis de un fertilizante y la cosecha (dentro de ciertos límites).
- **Causa inversa**: es Y la que provoca X. Se observa que los hospitales con más médicos tienen más enfermos, pero es porque se ponen más médicos donde hay más enfermos.
- **Variable de confusión**: una tercera variable Z influye en las dos. La venta de helados y los ahogamientos en el mar (ambos dependen del calor); el

chocolate y los premios Nobel (ambos dependen de la riqueza del país).
- **Casualidad**: con muchos datos y muchas variables, algunas correlaciones aparecen por puro azar. Existen colecciones de «correlaciones espurias», como la del número de películas de un actor y las muertes por ahogamiento en piscinas en un país durante diez años.

Para establecer una relación de causa se necesitan **experimentos controlados** (por ejemplo, ensayos clínicos con grupo de control y asignación al azar) o, cuando no son posibles, muchas pruebas coherentes, como en el caso del tabaco: la relación es fuerte, aparece en todos los estudios, va en el orden temporal correcto (primero se fuma), hay una relación dosis-respuesta y existe un mecanismo biológico que la explica.

Leer críticamente noticias que afirman «X aumenta el riesgo de Y» es una de las competencias más útiles de este tema.



13.7 La recta de regresión de Y sobre X

Cuando la correlación es fuerte, la nube se puede resumir con una recta que permita **estimar** el valor de Y a partir del de X. De todas las rectas posibles, se elige la que hace mínima la suma de los cuadrados de las distancias verticales de los puntos a la recta (los **residuos**). Es el **método de los mínimos cuadrados**, ideado por Legendre y Gauss hacia 1800.

Esa recta, llamada **recta de regresión de Y sobre X**, pasa por el centro de gravedad y tiene esta ecuación:

$$y - \bar{y} = (\sigma_{xy} / \sigma_x^2)\,(x - \bar{x})$$

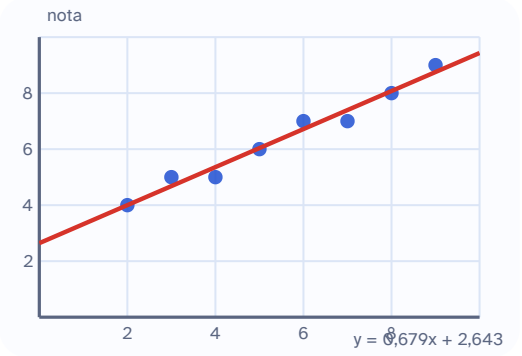
Su pendiente, $m = \sigma_{xy}/\sigma_x^2$, se llama **coeficiente de regresión** y tiene el mismo signo que r.

En el ejemplo: $m = 3{,}5625/5{,}25 \approx 0{,}679$. La recta es $y - 6{,}375 = 0{,}679(x - 5{,}5)$, es decir:

$$y \approx 0{,}679\,x + 2{,}643$$

Interpretación: por cada hora más de estudio semanal, la nota aumenta, de media, unos 0,68 puntos. Para estimar la nota de un alumno que estudia 6,5 horas: $y \approx 0{,}679 \cdot 6{,}5 + 2{,}643 \approx 7{,}06$.

Es importante no confundir variables: esta recta se usa para estimar **Y conocido X**. Para estimar X a partir de Y hay que usar otra recta distinta, la de X sobre Y.



13.8 La recta de regresión de X sobre Y

Si lo que se quiere es estimar X a partir de un valor de Y, se minimizan las distancias **horizontales** de los puntos a la recta. Se obtiene la **recta de regresión de X sobre Y**:

$$x - \bar{x} = (\sigma_{xy} / \sigma_y^2)\,(y - \bar{y})$$

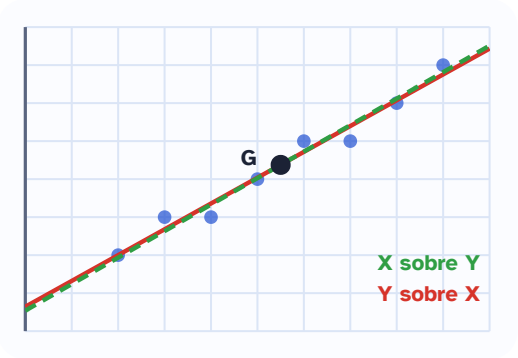
En el ejemplo: $\sigma_{xy}/\sigma_y^2 = 3{,}5625/2{,}484 \approx 1{,}434$. La recta es $x - 5{,}5 = 1{,}434(y - 6{,}375)$. Para estimar cuántas horas debe estudiar alguien que quiere sacar un 8: $x \approx 5{,}5 + 1{,}434 \cdot 1{,}625 \approx 7{,}83$ horas.

Si se despeja y en esta segunda recta para dibujarla en los mismos ejes, su pendiente es $\sigma_y^2/\sigma_{xy} \approx 0{,}697$, ligeramente distinta de la primera (0,679). Las dos

rectas:

- Se cortan siempre en el **centro de gravedad** $(\bar{x}, \bar{y})$.
- Son tanto más **parecidas** cuanto más fuerte es la correlación. Si $|r| = 1$, coinciden.
- Si $r = 0$, son perpendiculares: $y = \bar{y}$ y $x = \bar{x}$. Conocer X no ayuda a predecir Y.

Existe una relación sencilla entre los coeficientes de regresión y el coeficiente de correlación: el producto de las pendientes $m_{yx} = \sigma_{xy}/\sigma_x^2$ y $m_{xy} = \sigma_{xy}/\sigma_y^2$ es $\mathbf{r^2}$. En el ejemplo, $0{,}679 \cdot 1{,}434 \approx 0{,}973 \approx 0{,}986^2$. Esto permite calcular r a partir de las dos rectas.



13.9 Fiabilidad de las estimaciones

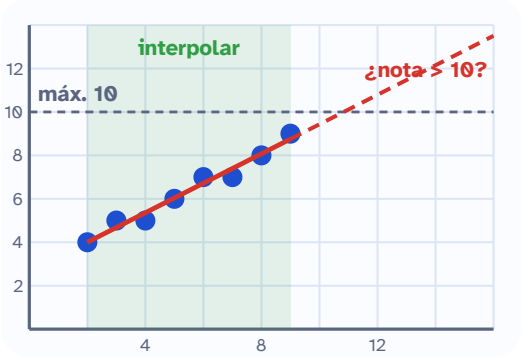
Una estimación hecha con la recta de regresión no es un valor exacto, sino una **predicción** aproximada. Su fiabilidad depende de varios factores:

- **El valor de |r|.** Cuanto más cerca de 1, más fiables son las estimaciones. Con $|r| < 0{,}5$ apenas tienen sentido.
- **El número de datos.** Con 5 puntos se puede obtener un r alto por casualidad; con 500, mucho menos.
- **No extrapolar.** Las estimaciones solo son fiables para valores de X **dentro del rango** de los datos (interpolación). Fuera de él (extrapolación), nada garantiza que la tendencia continúe. En el ejemplo, la recta predice para 20 horas de estudio una nota de 16,2, que no tiene sentido: la nota máxima es 10.

El **coeficiente de determinación** $R^2 = r^2$ indica qué proporción de la variabilidad de Y queda explicada por la recta de regresión. En el ejemplo, $r^2 \approx 0{,}973$: el 97,3 % de las diferencias en las notas se explica por las horas de estudio, y el 2,7 %

restante, por otros factores (la dificultad del examen, los nervios, la forma de estudiar…).

Los **residuos** $e_i = y_i - \hat{y}_i$ (dato real menos valor estimado) también dan información: si al dibujarlos se observa un patrón (por ejemplo, una curva), el modelo lineal no es el adecuado. En el ejemplo, el alumno con 2 horas tenía un 4 y la recta estima 4,0: residuo casi nulo. El de 9 horas, con un 9, tiene una estimación de 8,75 y un residuo de +0,25.



13.10 Tablas de doble entrada

Cuando hay muchos individuos y los valores se repiten, los datos se organizan en una **tabla de doble entrada**. Ejemplo: número de hermanos (X) y número de mascotas (Y) de 40 familias.

X \ Y	0	1	2	Total
0	6	3	1	10
1	5	8	3	16
2	2	6	6	14
Total	13	17	10	40

La última columna y la última fila son las **distribuciones marginales** de X y de Y. Con ellas se calculan las medias: $\bar{x} = (0 \cdot 10 + 1 \cdot 16 + 2 \cdot 14)/40 = 1{,}1$ e $\bar{y} = (0 \cdot 13 + 1 \cdot 17 + 2 \cdot 10)/40 = 0{,}925$.

Para la covarianza se suman los productos $x_i \cdot y_j$ multiplicados por la frecuencia de cada casilla: $\Sigma\, n_{ij}\, x_i\, y_j = 1 \cdot 1 \cdot 8 + 1 \cdot 2 \cdot 3 + 2 \cdot 1 \cdot 6 + 2 \cdot 2 \cdot 6 = 50$. Entonces $\sigma_{xy} = 50/40 - 1{,}1 \cdot 0{,}925 = 1{,}25 - 1{,}0175 = 0{,}2325$: correlación positiva.

Una fila o columna de la tabla, por sí sola, es una **distribución condicionada**: por ejemplo, entre las 14 familias con 2 hermanos, el reparto de mascotas es 2, 6, 6. Comparar las distribuciones condicionadas es otra forma de ver si hay relación: si las variables fueran independientes, todas las filas tendrían los mismos porcentajes. Esta idea conecta con la probabilidad condicionada del tema siguiente.

X \ Y	0	1	2	Total
0	6	3	1	10
1	5	8	3	16
2	2	6	6	14
Total	13	17	10	40

13.11 Cálculo con calculadora y hoja de cálculo

Los cálculos de este tema son largos y es fácil equivocarse. En la práctica se hacen con herramientas digitales, y lo importante es saber **interpretar** los resultados.

Con la calculadora científica, en el modo de estadística de dos variables (STAT, modo A + BX en muchos modelos): se introducen los pares en dos columnas y la calculadora da $\bar{x}$, $\bar{y}$, σ_x, σ_y, los sumatorios y, directamente, los coeficientes A (ordenada) y B (pendiente) de la recta de regresión de Y sobre X y el coeficiente r. También permite estimar $\hat{y}$ para un valor de x.

Con una hoja de cálculo (LibreOffice Calc, Excel o similar), si los datos están en A2:A9 y B2:B9:

Cálculo	Fórmula
Medias	=PROMEDIO(A2:A9)
Covarianza (poblacional)	=COVARIANZA.P(A2:A9;B2:B9)
Coeficiente r	=COEF.DE.CORREL(A2:A9;B2:B9)
Pendiente	=PENDIENTE(B2:B9;A2:A9)
Ordenada	=INTERSECCION.EJE(B2:B9;A2:A9)

Además, al crear un gráfico de dispersión se puede añadir una «línea de tendencia» lineal y pedir que muestre la ecuación y el valor de R^2.

Cuidado: algunas herramientas calculan la covarianza y la desviación típica **muestrales**, dividiendo entre n − 1 en lugar de n. El coeficiente r y la recta de regresión no cambian, pero la covarianza sí. En este curso se usan las fórmulas con n.

Cálculo	Función
covarianza	COVARIANZA.P
r de Pearson	COEF.DE.CORREL
pendiente	PENDIENTE
ordenada	INTERSECCION.EJE

13.12 Ajustes no lineales

No todas las relaciones son lineales. Si la nube de puntos tiene forma de curva, una recta da malas estimaciones. Algunos modelos no lineales se pueden ajustar **transformando** las variables para que la relación se vuelva lineal.

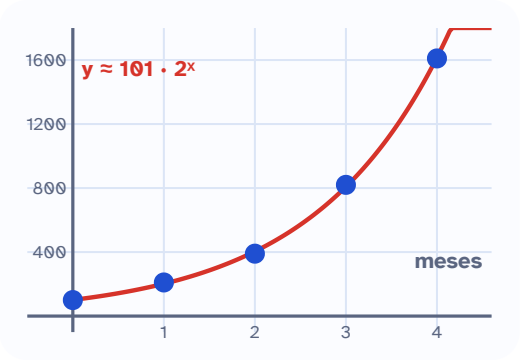
Ajuste exponencial. Si se sospecha que $y = a \cdot b^x$ (crecimiento de una población, de un capital o de unos contagios), se toman logaritmos: $\ln y = \ln a + x \cdot \ln b$. La variable $Y' = \ln y$ depende linealmente de x. Se calcula la recta de regresión de Y' sobre X y se deshace el cambio.

Ejemplo: el número de usuarios de una aplicación en sus primeros meses es 100, 210, 390, 820 y 1.610 (meses 0 a 4). Los logaritmos neperianos son 4,61; 5,35; 5,97; 6,71; 7,38, que crecen casi de forma constante (unos 0,7 por mes). La recta de regresión de ln y sobre x es aproximadamente ln y = 4,62 + 0,69x, de modo que y ≈ e^4,62 · e^(0,69x) ≈ 101 · 2^x: los usuarios se duplican cada mes.

Ajuste potencial. Si $y = a \cdot x^b$ (como el período de los planetas frente a su distancia al Sol, en la tercera ley de Kepler), se toman logaritmos en ambas variables: ln y = ln a + b ln x.

Las hojas de cálculo ofrecen directamente líneas de tendencia exponenciales, logarítmicas, potenciales y polinómicas. Para elegir, se mira la forma de la nube,

el valor de R^2 y, sobre todo, si el modelo tiene sentido en el contexto.



Estadística bidimensional de un vistazo

Nube	Covarianza	Correlación	Regresión
pares (x_i, y_i)	**$\sigma_{xy} = \Sigma xy/n - \bar{x}\bar{y}$**	**$r = \sigma_{xy}/(\sigma_x\sigma_y)$**	**$y - \bar{y} = (\sigma_{xy}/\sigma_x^2)(x - \bar{x})$**
forma · sentido	signo = sentido	$-1 \le r \le 1$	pasa por G
intensidad	depende de unidades	$\lvert r \rvert$ cerca de 1: fuerte	interpolar, no extrapolar
atípicos	G = $(\bar{x}, \bar{y})$	no implica causa	r^2 explicado

Ejercicios

1. **Clasifica la correlación esperada: (a) temperatura y consumo de calefacción; (b) estatura de padres e hijos; (c) número de pie y nota de inglés.**

2. **Calcula el centro de gravedad de (2, 5), (4, 6), (6, 9), (8, 10).**

3. **Calcula la covarianza de (1, 6), (2, 4), (3, 3), (4, 1).**

4. **Si $\sigma_{xy} = 12$, $\sigma_x = 4$ y $\sigma_y = 3{,}5$, calcula r.**

5. **¿Qué valores puede tomar r? ¿Qué significa $r = -1$?**

6. **Asocia cada r con su nube: $r = 0{,}95$; $r = -0{,}4$; $r = 0{,}05$.**

7. **La recta de regresión de Y sobre X es $y = 2x + 3$. Estima y para $x = 4$.**

8. **Si $\bar{x} = 10$, $\bar{y} = 20$, $\sigma x^2 = 4$ y $\sigma xy = 6$, halla la recta de regresión de Y sobre X.**

9. **Con $r^2 = 0{,}64$, ¿qué porcentaje de la variabilidad de Y explica la recta?**

10. **Explica por qué no tiene sentido usar la recta $y = 0{,}679x + 2{,}643$ para estimar la nota de quien estudia 30 horas.**

11. **Da un ejemplo de correlación causada por una tercera variable.**

12. **Calcula las medias marginales de la tabla: X = 1 (frec. 4), X = 2 (frec. 6); Y = 0 (frec. 3), Y = 1 (frec. 7).**

13. **Para (1, 1), (2, 3), (3, 4), (4, 4), (5, 6), calcula r.**

14. **Con los datos anteriores, halla las dos rectas de regresión.**

15. **En 6 ciudades se mide la altitud x (en cientos de metros) y la temperatura media y (°C): (0, 18), (2, 17), (5, 15), (7, 13), (9, 12), (12, 10). Halla r y la recta de Y sobre X.**

16. **Con la recta anterior, estima la temperatura a 800 m y comenta la fiabilidad.**

17. **Las rectas de regresión son y = −0,5x + 8 y x = −1,2y + 13. Halla r y el centro de gravedad.**

18. **Calcula la covarianza de la tabla de doble entrada: (X = 1, Y = 1): 3; (1, 2): 1; (2, 1): 1; (2, 2): 5.**

19. **¿Cómo cambian la covarianza y r si todas las x se multiplican por 10?**

20. **Un estudio encuentra r = 0,8 entre el número de horas de televisión de los niños y su peso. ¿Puede afirmarse que ver la televisión engorda?**

21. **Demuestra que la recta de regresión de Y sobre X pasa por el centro de gravedad.**

22. **Si $\sigma x = 2$, $\sigma y = 5$ y $r = -0{,}6$, calcula la covarianza y la pendiente de la recta de Y sobre X.**

23. **¿Por qué cuando $r = 0$ las rectas de regresión son perpendiculares?**

24. **Demuestra que el producto de las pendientes de las dos rectas de regresión es r^2.**

25. **Una población de bacterias vale 50, 100, 210, 390 a las 0, 1, 2, 3 horas. Ajusta un modelo exponencial con logaritmos.**

26. **Explica, con un ejemplo dibujado, por qué dos variables pueden tener $r \approx 0$ aunque estén muy relacionadas.**

27. **En una muestra con $\bar{x} = 4$, $\bar{y} = 10$, se sabe que la recta de Y sobre X tiene pendiente 2 y $r = 0{,}8$. Si $\sigma x = 1{,}5$, halla σy y la recta de X sobre Y.**

28. **Añade al ejemplo de las horas el punto (9, 2) (un alumno enfermo). Calcula aproximadamente el nuevo r y comenta.**

29. **Investiga el ejemplo del «cuarteto de Anscombe» y explica qué enseña.**

30. **Demuestra que si todos los puntos están sobre la recta $y = ax + b$ ($a \neq 0$), entonces $|r| = 1$.**

Practica

1. **Una variable bidimensional estudia...**

   A) un carácter
   B) dos caracteres en cada individuo
   C) dos poblaciones
   D) dos muestras

2. **La representación de una variable bidimensional es...**

   A) un histograma
   B) un pictograma
   C) un diagrama de sectores
   D) una nube de puntos

3. **Si al aumentar X disminuye Y, la correlación es...**

   A) negativa
   B) positiva
   C) nula
   D) funcional

4. **El centro de gravedad es...**

   A) $(\sigma x, \sigma y)$
   B) $(0, 0)$
   C) $(\bar{x}, \bar{y})$
   D) el punto más alto

5. **La covarianza se calcula como...**

   A) $\Sigma xy - x\bar{y}$
   B) $\Sigma xy/n - x\bar{y}$
   C) $\Sigma xy/n$
   D) $x\bar{y}$

6. **Si $\sigma xy < 0$, la correlación es...**

   A) positiva
   B) perfecta
   C) nula
   D) negativa

7. **El coeficiente de correlación r está siempre entre...**

A) -1 y 1

B) 0 y 1

C) 0 y 100

D) $-\infty$ y ∞

8. **$r = \sigma xy/(\ldots)$**

A) $\sigma x + \sigma y$

B) σx^2

C) $\sigma x \cdot \sigma y$

D) n

9. **Si $r = 0{,}98$, la correlación es...**

A) débil

B) positiva muy fuerte

C) negativa

D) nula

10. **Si $r = -1$...**

A) no hay relación

B) la nube es circular

C) la covarianza es 0

D) los puntos están en una recta decreciente

11. **Una correlación alta...**

A) no implica causalidad

B) demuestra causa

C) es imposible

D) siempre es positiva

12. **La recta de regresión de Y sobre X sirve para...**

A) estimar X dado Y

B) calcular r

C) estimar Y dado X

D) nada

13. **Su pendiente es...**

A) $\sigma xy/\sigma y^2$

B) $\sigma xy/\sigma x^2$

C) r

D) $\sigma x/\sigma y$

14. **Las dos rectas de regresión se cortan en...**

A) el origen

B) no se cortan

C) el eje X

D) el centro de gravedad

15. **Si r = 1, las dos rectas de regresión...**

A) coinciden

B) son perpendiculares

C) son paralelas

D) no existen

16. **Si r = 0, las rectas de regresión son...**

A) iguales

B) paralelas

C) perpendiculares

D) la bisectriz

17. **El producto de las dos pendientes de regresión es...**

A) r

B) r^2

C) 1

D) σxy

18. **Estimar fuera del rango de los datos se llama...**

A) interpolar

B) regresar

C) tipificar

D) extrapolar

19. **r^2 = 0,81 significa que la recta explica...**

A) el 81 %

B) el 9 %

C) el 90 %

D) el 19 %

20. **Para ajustar $y = a \cdot b^x$ se toman logaritmos de...**

A) x

B) a

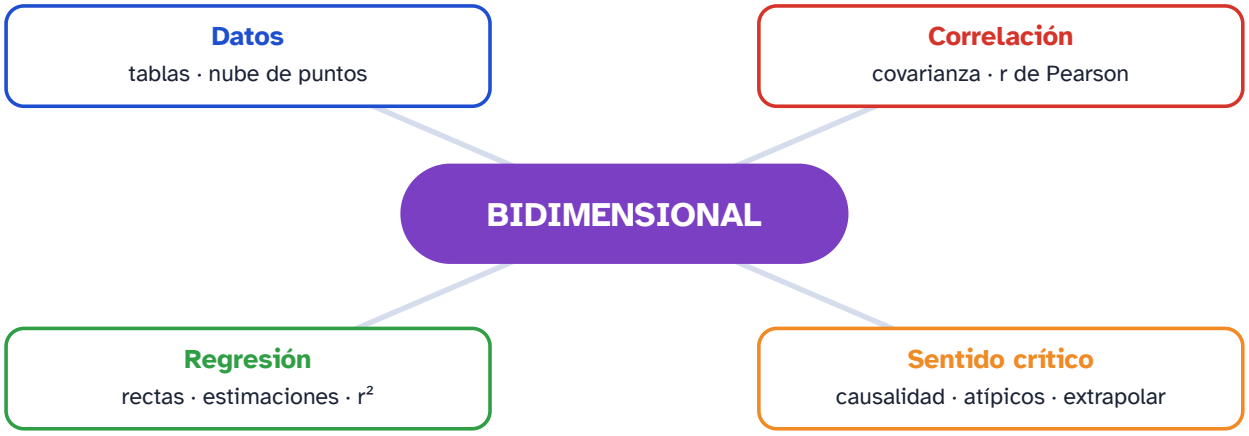
C) y

D) b

Explícalo con tus palabras

Incluye: Qué información da una nube de puntos que no dan las medias; Por qué la covarianza depende de las unidades y r no; Por qué una correlación alta no demuestra una relación de causa; Qué diferencia hay entre las dos rectas de regresión; Por qué no hay que extrapolar con la recta de regresión.

Resumen



Glosario

Variable bidimensional	Par de caracteres (X, Y) estudiados en cada individuo.
Nube de puntos	Representación de los pares (x_i, y_i) en ejes cartesianos.
Correlación	Relación estadística entre dos variables.
Correlación positiva	Al aumentar una variable, la otra tiende a aumentar.
Correlación negativa	Al aumentar una variable, la otra tiende a disminuir.
Centro de gravedad	Punto $(\bar{x}, \bar{y})$.
Covarianza	$\sigma_{xy} = \Sigma x_i y_i / n - \bar{x}\bar{y}$.
Coeficiente de correlación	$r = \sigma_{xy}/(\sigma_x \sigma_y)$, entre -1 y 1.
Dependencia funcional	Relación exacta: $\lvert r\rvert = 1$ en el caso lineal.
Recta de regresión	Recta que mejor ajusta la nube por mínimos cuadrados.
Coeficiente de regresión	Pendiente de la recta de regresión.
Residuo	Diferencia entre el valor real y el estimado.
Interpolación	Estimación dentro del rango de los datos.
Extrapolación	Estimación fuera del rango de los datos.
Coeficiente de determinación	r^2: proporción de variabilidad explicada.

Variable de confusión	Tercera variable que influye en las otras dos.

Tarjetas de repaso

Recórtalas: pregunta delante, respuesta detrás.

Centro de gravedad

$(\bar{x}, \bar{y})$

Covarianza

$\sigma xy = \Sigma x_i y_i / n - \bar{x} \cdot \bar{y}$

Desviación típica

$\sigma x = \sqrt{(\Sigma x_i^2 / n - \bar{x}^2)}$

Coeficiente de Pearson

$r = \sigma xy / (\sigma x \cdot \sigma y)$

Valores de r

$-1 \leq r \leq 1$; $|r| = 1$ ajuste perfecto

Recta de Y sobre X

$y - \bar{y} = (\sigma xy / \sigma x^2)(x - \bar{x})$

Recta de X sobre Y

$x - \bar{x} = (\sigma xy / \sigma y^2)(y - \bar{y})$

Producto de pendientes

r^2

Coeficiente de determinación

r^2: % de variabilidad explicada

Interpolar / extrapolar

Dentro / fuera del rango de datos

Correlación ≠ causalidad

Puede haber terceras variables o azar

Ajuste exponencial

Regresión de ln y sobre x

Soluciones

1. **B)** Pares (x, y).
2. **D)** Diagrama de dispersión.
3. **A)** Inversa.
4. **C)** Las medias.
5. **B)** Fórmula abreviada.
6. **D)** Mismo signo.
7. **A)** Propiedad.
8. **C)** Pearson.
9. **B)** Cercana a 1.
10. **D)** Dependencia funcional.
11. **A)** Puede haber terceras variables.
12. **C)** Minimiza distancias verticales.
13. **B)** Coeficiente de regresión.
14. **D)** Ambas pasan por $(\bar{x}, \bar{y})$.
15. **A)** Ajuste perfecto.
16. **C)** $y = \bar{y}$ y $x = \bar{x}$.
17. **B)** $\sigma xy^2/(\sigma x^2 \sigma y^2)$.
18. **D)** Poco fiable.
19. **A)** Coeficiente de determinación.
20. **C)** ln y es lineal en x.

Soluciones de los ejercicios

1. (a) Negativa; (b) positiva; (c) nula.
2. (5; 7,5).
3. $\bar{x} = 2{,}5$, $\bar{y} = 3{,}5$. $\Sigma xy = 6 + 8 + 9 + 4 = 27$. $\sigma_{xy} = 6{,}75 - 8{,}75 = -2$.
4. $r = 12/14 \approx 0{,}857$: correlación positiva fuerte.
5. Entre -1 y 1. $r = -1$: todos los puntos sobre una recta decreciente.
6. 0,95: nube creciente muy estrecha; $-0{,}4$: decreciente y dispersa; 0,05: sin forma.
7. $\hat{y} = 11$.
8. $m = 1{,}5$: $y - 20 = 1{,}5(x - 10) \rightarrow y = 1{,}5x + 5$.
9. El 64 %.
10. Es extrapolación: fuera del rango [2, 9] y daría 23,0, imposible en una escala de 10.
11. Número de bomberos en un incendio y daños causados: ambos dependen del tamaño del incendio.
12. $\bar{x} = (4 + 12)/10 = 1{,}6$; $\bar{y} = 7/10 = 0{,}7$.
13. $\bar{x} = 3$, $\bar{y} = 3{,}6$. $\sigma_x^2 = 2$, $\sigma_y^2 = 15{,}6 - 12{,}96 \approx 2{,}64$. $\Sigma xy = 1 + 6 + 12 + 16 + 30 = 65 \rightarrow \sigma_{xy} = 13 - 10{,}8 = 2{,}2$. $r = 2{,}2/(1{,}414 \cdot 1{,}625) \approx 0{,}957$.
14. Y/X: $m = 1{,}1 \rightarrow y = 1{,}1x + 0{,}3$. X/Y: $m = 2{,}2/2{,}64 \approx 0{,}833 \rightarrow x - 3 = 0{,}833(y - 3{,}6)$.
15. $\bar{x} = 5{,}83$; $\bar{y} = 14{,}17$. $\sigma_x^2 \approx 16{,}47$; $\sigma_{xy} \approx -11{,}31$; $\sigma_y^2 \approx 7{,}81$. $r \approx -0{,}997$. $y \approx -0{,}686x + 18{,}17$.
16. $\hat{y} \approx -0{,}686 \cdot 8 + 18{,}17 \approx 12{,}7$ °C. Fiable: $|r| \approx 0{,}997$ y 8 está en el rango.
17. $r^2 = 0{,}6 \rightarrow r \approx -0{,}775$ (pendientes negativas). Centro: $x = -1{,}2(-0{,}5x + 8) + 13 \rightarrow 0{,}4x = 3{,}4 \rightarrow \bar{x} = 8{,}5$, $\bar{y} = 3{,}75$.
18. $N = 10$, $\bar{x} = 1{,}6$, $\bar{y} = 1{,}6$. $\Sigma nxy = 3 + 2 + 2 + 20 = 27$. $\sigma_{xy} = 2{,}7 - 2{,}56 = 0{,}14$.
19. La covarianza se multiplica por 10; r no cambia (no tiene unidades).
20. No directamente: puede influir la falta de ejercicio, la alimentación o el entorno familiar. Hace falta un estudio experimental o más pruebas.
21. Su ecuación es $y - \bar{y} = m(x - \bar{x})$: para $x = \bar{x}$, $y = \bar{y}$.
22. $\sigma_{xy} = -0{,}6 \cdot 2 \cdot 5 = -6$. $m = -6/4 = -1{,}5$.
23. Si $\sigma_{xy} = 0$, las rectas son $y = \bar{y}$ (horizontal) y $x = \bar{x}$ (vertical).
24. $(\sigma_{xy}/\sigma_x^2) \cdot (\sigma_{xy}/\sigma_y^2) = \sigma_{xy}^2/(\sigma_x^2\sigma_y^2) = r^2$.
25. ln y: 3,91; 4,61; 5,35; 5,97. Recta: $\ln y \approx 3{,}92 + 0{,}69x$. $y \approx e^{3{,}92} \cdot e^{(0{,}69x)} \approx 50 \cdot 2^x$: se duplica cada hora.
26. Si $y = x^2$ con $x \in \{-2, -1, 0, 1, 2\}$, la covarianza es 0 por simetría, pero y depende exactamente de x. La relación no es lineal.
27. $\sigma_{xy} = 2 \cdot 2{,}25 = 4{,}5$. $\sigma_y = \sigma_{xy}/(r\,\sigma_x) = 4{,}5/1{,}2 = 3{,}75$. Pendiente X/Y: $4{,}5/14{,}0625 = 0{,}32$. $x - 4 = 0{,}32(y - 10)$.
28. Con 9 puntos: $\bar{x} = 5{,}89$, $\bar{y} = 5{,}89$; $\Sigma xy = 327$, $\Sigma x^2 = 365$, $\Sigma y^2 = 349$. $\sigma_{xy} \approx 1{,}65$; $\sigma_x \approx 2{,}42$; $\sigma_y \approx 2{,}02$. $r \approx 0{,}34$: un solo valor atípico reduce mucho la correlación.
29. Son cuatro conjuntos de datos con las mismas medias, varianzas, $r \approx 0{,}816$ y recta de regresión, pero nubes completamente distintas (lineal, curva, con atípico…). Enseña a dibujar siempre los datos.

30. $\bar{y} = a\,\bar{x} + b$, así que $y_i - \bar{y} = a(x_i - \bar{x})$. Entonces $\sigma_{xy} = a\,\sigma_x^2$ y $\sigma_y = |a|\,\sigma_x$. $r = a\,\sigma_x^2/(\sigma_x \cdot |a|\,\sigma_x) = a/|a| = \pm 1$.