Estadística bidimensional

Nombre: _____ Fecha: _____

Qué vas a aprender

- Organizar datos de dos variables y representarlos en una nube de puntos
- Interpretar la correlación: positiva, negativa, fuerte o débil
- Usar la recta de regresión para hacer predicciones con sentido crítico
- Calcular medias, desviaciones típicas y covarianza de una variable bidimensional
- Interpretar la correlación sin confundirla con la causalidad

Para pensar

¿Los alumnos que duermen más sacan mejores notas? ¿Cómo lo comprobarías con datos de tu clase?

Explicación

Variables bidimensionales y nube de puntos

Cuando estudiamos **dos variables a la vez** en cada individuo (altura y peso, horas de estudio y nota) tenemos pares (x, y). Cada par se dibuja como un punto: es la nube de puntos o diagrama de dispersión.



Repaso: media y desviación típica

Antes de estudiar dos variables a la vez conviene recordar cómo se resume una. La **media** $\bar{x}$ es la suma de los datos dividida entre su número. La **varianza** mide cuánto se separan los datos de la media: es la media de los cuadrados menos el cuadrado de la media, $\sigma^2 = \Sigma x^2/N - \bar{x}^2$. Su raíz es la **desviación típica** σ, que se mide en las mismas unidades que los datos. Para comparar la dispersión de variables con distintas unidades se usa el **coeficiente de variación**, $CV = \sigma / \bar{x}$, que suele darse en porcentaje.

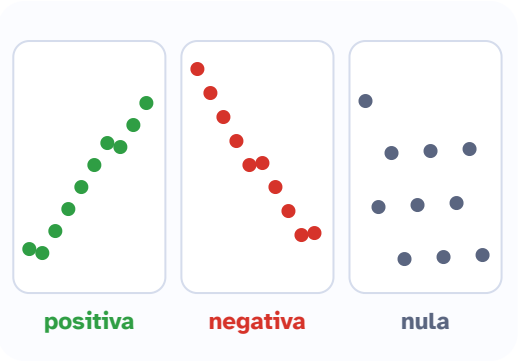
undefined

Tipos de correlación

La **correlación** mide cómo se relacionan las dos variables:

- **Positiva**: cuando una sube, la otra tiende a subir.
- **Negativa**: cuando una sube, la otra tiende a bajar.
- **Nula**: no hay relación clara.

Cuanto más se parecen los puntos a una recta, más fuerte es la correlación.



La covarianza

La **covarianza** mide si las dos variables varían juntas. Se calcula como la media de los productos menos el producto de las medias: $\sigma_{xy} = \Sigma xy/N - \bar{x} \cdot \bar{y}$. Si es **positiva**, cuando una variable crece la otra tiende a crecer; si es **negativa**, cuando una crece la otra tiende a bajar; si es cercana a cero, no hay relación lineal. Su inconveniente es que depende de las unidades: no es lo mismo medir en metros que en centímetros. Por eso se divide entre las desviaciones típicas y se obtiene el coeficiente de correlación.

undefined

El coeficiente de correlación r

Es un número entre **–1 y 1** que resume la correlación. Su signo dice el sentido y su tamaño la fuerza: r cerca de 1 o –1 es correlación fuerte; cerca de 0, débil o nula. Se calcula con la calculadora en modo estadística (REG o LINE).



Calcular r paso a paso

Para hallar r con pocos datos se organiza una **tabla** con las columnas x, y, x^2, y^2 y x·y, y se suman. Con esas sumas se calculan las medias, las desviaciones típicas y

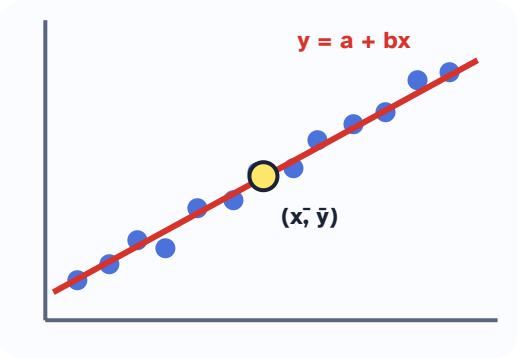
la covarianza, y por último $r = \sigma_{xy} / (\sigma_x \cdot \sigma_y)$. El resultado siempre está entre –1 y 1. La calculadora científica en modo estadístico (REG o STAT) da r directamente, igual que las hojas de cálculo con la función COEF.DE.CORREL. Conviene igualmente hacer la nube de puntos: un r bajo puede esconder una relación curva, no lineal.

x	y	x^2	y^2	xy
1	2	1	4	2
2	3	4	9	6
3	5	9	25	15
4	6	16	36	24
10	**16**	**30**	**74**	**47**

undefined

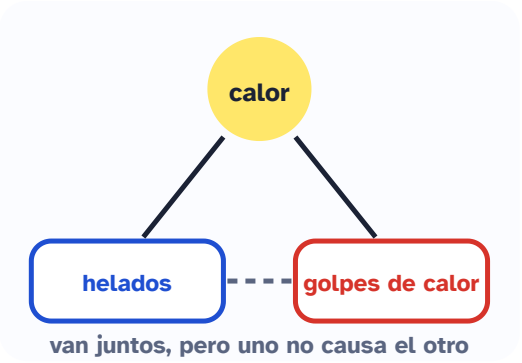
La recta de regresión

Es la recta que mejor se ajusta a la nube: pasa por el punto medio $(\bar{x}, \bar{y})$ y deja los puntos lo más cerca posible. Su ecuación $y = a + bx$ la da la calculadora, y sirve para **predecir**: si $y = 3 + 0{,}8x$, con 5 horas de estudio se espera una nota de $3 + 4 = 7$.



Predecir con cuidado

Las predicciones son **fiables** si la correlación es fuerte y si no te alejas del rango de los datos. Además, correlación no es causalidad: las ventas de helados y los golpes de calor suben juntos, pero los helados no causan golpes de calor; ambos dependen del verano.

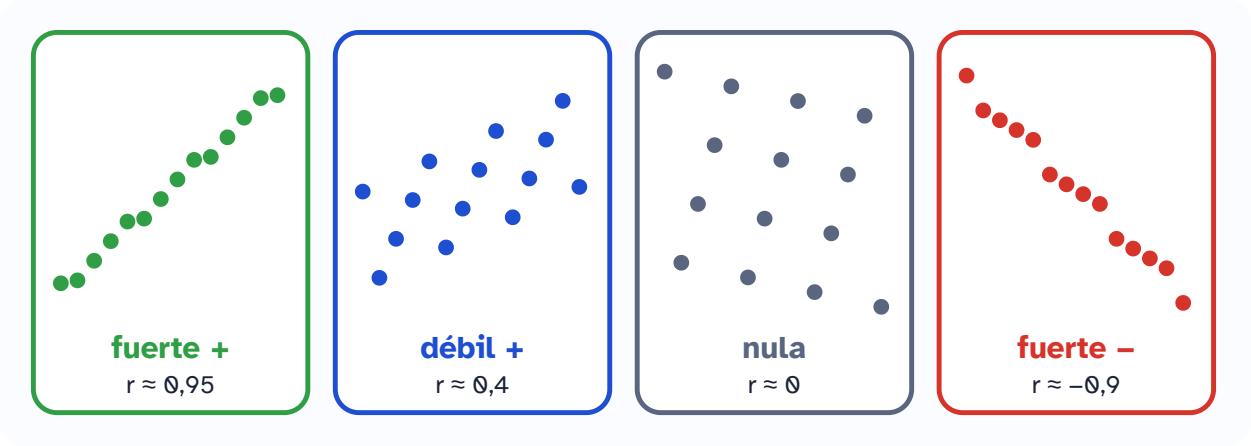


Correlación no es causalidad

Que dos variables estén muy correlacionadas no significa que una cause la otra. Las ventas de helados y los ahogamientos están correlacionados, pero no porque los helados ahoguen: ambos aumentan en verano por el calor, que es una **variable oculta**. Otras veces la correlación es pura **casualidad**, sobre todo con pocos datos. Para afirmar que algo causa otra cosa hace falta un experimento controlado, como los ensayos clínicos de los medicamentos, en los que se compara un grupo tratado con otro que no lo está. Desconfía de los titulares que concluyen causas a partir de una simple correlación.

undefined

Cómo leer una nube de puntos



Ejercicios

1. **Calcula la media y la desviación típica de 2, 4, 4, 6, 9.**

2. **¿Qué significa una covarianza negativa?**

3. **Clasifica la correlación: horas de estudio y nota; edad de un coche y su precio; número de calzado y nota de Historia.**

4. **Si $\sigma_{xy} = 12$, $\sigma_x = 4$ y $\sigma_y = 5$, calcula r e interprétalo.**

5. **¿Puede ser r = 1,3? ¿Por qué?**

6. **Calcula la covarianza de x: 1, 2, 3; y: 6, 4, 2.**

7. **La recta de regresión del peso (kg) sobre la altura (cm) es y = 0,9x – 90. Estima el peso de alguien de 170 cm.**

8. **¿Es fiable usar la recta anterior para estimar el peso de un bebé de 50 cm? ¿Por qué?**

9. **Pon un ejemplo de correlación causada por una variable oculta.**

10. **Un conjunto tiene $\bar{x} = 50$ y $\sigma = 5$, y otro $\bar{x} = 10$ y $\sigma = 2$. ¿Cuál es más homogéneo?**

Practica

1. **Si al aumentar x la variable y tiende a disminuir, la correlación es...**

   A) Positiva

   B) Negativa

   C) Nula

2. **¿Qué valor de r indica la correlación más fuerte?**

   A) 0,5

   B) −0,95

   C) 0,1

3. **La recta de regresión siempre pasa por...**

   A) el origen

   B) el punto $(\bar{x}, \bar{y})$

   C) el primer dato

4. **Con y = 2 + 0,5x, ¿qué valor se predice para x = 10?**

   A) 7

   B) 12

   C) 5

5. **Si r = 0,9 entre el número de bomberos en un incendio y los daños, ¿los bomberos causan los daños?**

   A) Sí

   B) No: los incendios grandes causan ambas cosas

   C) Solo si r = 1

6. **La covarianza se calcula como...**

   A) $\Sigma xy/N - x\bar{y}$

   B) $\Sigma x/N$

   C) $\sigma_x \cdot \sigma_y$

7. **Un r alto entre dos variables demuestra que...**

   A) una causa la otra

   B) están relacionadas linealmente

   C) son iguales

8. **El coeficiente de variación sirve para...**

A) comparar dispersiones

B) calcular la media

C) dibujar la recta

9. **Si r = 0, puede haber...**

A) una relación curva

B) una relación lineal perfecta

C) covarianza positiva grande

10. **La desviación típica es...**

A) la raíz de la varianza

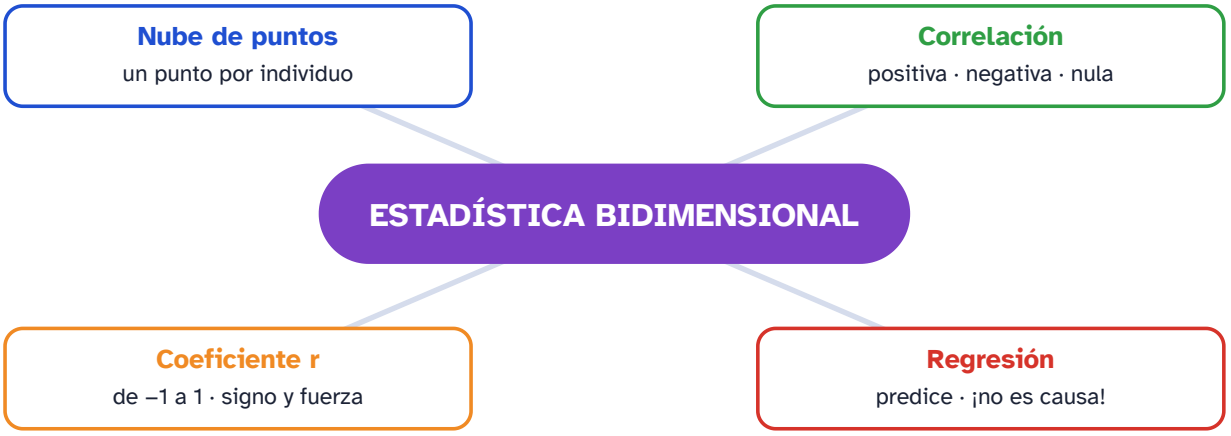
B) el cuadrado de la varianza

C) la media de los datos

Explícalo con tus palabras

Incluye: Qué es una variable bidimensional y cómo se dibuja; Qué significan el signo y el tamaño de r; Para qué sirve la recta de regresión; Por qué correlación no significa causalidad.

Resumen



Tarjetas de repaso

Recórtalas: pregunta delante, respuesta detrás.

¿Qué es una nube de puntos?

La representación de pares (x, y), un punto por individuo.

Correlación negativa

Al aumentar una variable, la otra tiende a disminuir.

¿Entre qué valores está r?

Entre –1 y 1.

¿Por qué punto pasa la recta de regresión?

Por $(\bar{x}, \bar{y})$, las medias de las dos variables.

Correlación y causalidad

Que dos variables vayan juntas no prueba que una cause la otra.

Covarianza

$\sigma_{xy} = \Sigma xy/N - \bar{x}\bar{y}$; su signo indica si las variables crecen juntas.

Coeficiente de variación

$CV = \sigma / \bar{x}$; compara dispersiones de distintos conjuntos.

Variable oculta

Tercera variable que explica la correlación entre otras dos.

Soluciones

1. **B)** Van en sentidos opuestos.
2. **B)** Lo que importa para la fuerza es lo cerca que está de 1 o –1.
3. **B)** Pasa por el centro de gravedad de la nube.
4. **A)** $2 + 0{,}5 \cdot 10 = 7$.
5. **B)** Correlación no es causalidad: hay una tercera variable, el tamaño del incendio.
6. **A)** Media de productos menos producto de medias.
7. **B)** Correlación no es causalidad.
8. **A)** $CV = \sigma / \bar{x}$.
9. **A)** r solo mide relación lineal.
10. **A)** Mismas unidades que los datos.

Soluciones de los ejercicios

1. $\bar{x} = 5$; $\sigma^2 = 153/5 - 25 = 5{,}6$; $\sigma \approx 2{,}37$.
2. Que cuando una variable aumenta, la otra tiende a disminuir.
3. Positiva, negativa y nula.
4. $r = 12 / 20 = 0{,}6$: correlación positiva moderada.
5. No: r siempre está entre -1 y 1.
6. $\Sigma xy/3 = 20/3 \approx 6{,}67$; $\bar{x} \cdot \bar{y} = 2 \cdot 4 = 8$; $\sigma_{xy} \approx -1{,}33$.
7. $0{,}9 \cdot 170 - 90 = 63$ kg.
8. No: daría -45 kg. Es una extrapolación fuera del rango de los datos.
9. Uso de crema solar y quemaduras: ambas crecen con los días de sol (también helados y ahogamientos).
10. CV: 10 % frente a 20 %; el primero es más homogéneo.