Estadística bidimensional

Nombre: _____ Fecha: _____

Qué vas a aprender

- Organizar datos de dos variables en tablas y representarlos en un diagrama de dispersión
- Describir el tipo y la fuerza de la correlación a partir de la nube de puntos
- Calcular e interpretar el centro de gravedad, la covarianza y el coeficiente de correlación
- Obtener la recta de regresión y usarla para hacer estimaciones razonables
- Distinguir correlación de causalidad y valorar la fiabilidad de las predicciones
- Usar la calculadora y la hoja de cálculo para el análisis bidimensional

Para pensar

¿Los alumnos que duermen más sacan mejores notas? ¿Cómo lo comprobarías con datos de tu clase?

Explicación

12.1 Variables estadísticas bidimensionales

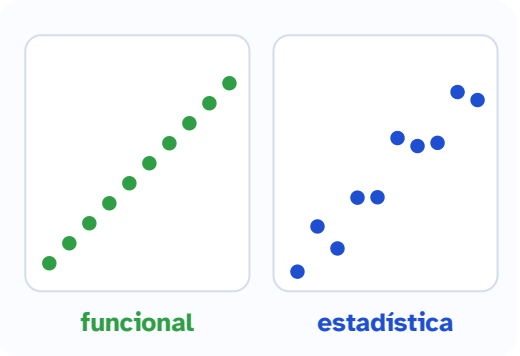
En los cursos anteriores estudiaste variables estadísticas de una en una: la altura de los alumnos, las notas de un examen, el número de hermanos. Una **variable estadística bidimensional** se obtiene al observar dos características a la vez en cada individuo de la población. Se representa como un par (X, Y) y cada individuo aporta un par de valores (x_i, y_i).

Ejemplos:

- Horas de estudio semanales (X) y nota del examen (Y) de cada alumno.
- Temperatura máxima (X) y número de helados vendidos (Y) en cada día de verano.
- Antigüedad (X) y precio (Y) de cada coche de segunda mano de un concesionario.
- Altura (X) y peso (Y) de un grupo de personas.

La pregunta clave de este tema es: **¿existe relación entre X e Y?** Y si existe, ¿de qué tipo es, cómo de fuerte es y se puede usar para predecir una variable a partir de la otra?

Cuando entre dos variables hay una relación exacta, como entre el lado de un cuadrado y su área, se dice que hay una **dependencia funcional**: conocido x, y queda determinado. En estadística casi nunca ocurre eso: dos alumnos que estudian lo mismo pueden sacar notas distintas. Hablamos entonces de **dependencia estadística** o correlación: hay una tendencia, pero con variaciones.



12.2 Tablas de datos bidimensionales

Los datos de una variable bidimensional se organizan en tablas. Hay dos formatos principales:

- **Tabla simple** o de pares: dos filas (o columnas), una con los valores de X y otra con los de Y. Cada columna es un individuo. Se usa cuando hay pocos datos o casi no se repiten.
- **Tabla de doble entrada**: los valores de X se colocan en las filas y los de Y en las columnas; cada casilla indica la **frecuencia** con la que aparece ese par. Es útil cuando hay muchos datos y se repiten, por ejemplo al cruzar el número de hermanos con el número de mascotas de toda una clase.

Ejemplo de tabla simple, con las horas de estudio semanales y la nota de cinco alumnos:

Horas (X)	1	2	3	4	5
Nota (Y)	3	4	6	7	10

A partir de una tabla de doble entrada se pueden obtener las **distribuciones marginales**: las de cada variable por separado, sumando filas o columnas. Con ellas se calculan, como ya sabes, las medias y desviaciones típicas de X y de Y. En este tema trabajaremos sobre todo con tablas simples, que es como se presentan los datos en la mayoría de los estudios y en las hojas de cálculo.

Un par (x_i, y_i) por alumno

Horas (X)	1	2	3	4	5
Nota (Y)	3	4	6	7	10

5 individuos → 5 puntos

12.3 El diagrama de dispersión

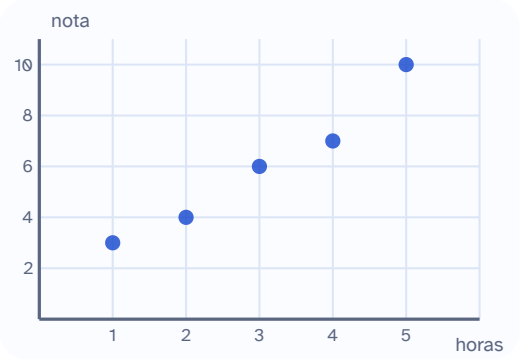
La forma más clara de ver si dos variables están relacionadas es dibujar un **diagrama de dispersión** o **nube de puntos**: en unos ejes cartesianos se representa cada par (x_i, y_i) como un punto. Si un par se repite, se puede indicar con un punto más grande o con su frecuencia al lado.

Al mirar la nube nos fijamos en tres cosas:

1. La **dirección**: ¿la nube sube (al aumentar X, tiende a aumentar Y) o baja?
2. La **forma**: ¿los puntos se agrupan en torno a una recta o a una curva?
3. La **dispersión**: ¿los puntos están muy pegados a esa línea imaginaria o muy separados?

En el ejemplo de las horas de estudio, los puntos (1, 3), (2, 4), (3, 6), (4, 7) y (5, 10) forman una nube que sube claramente y que se agrupa bastante cerca de una recta. Hay, por tanto, una relación positiva y bastante fuerte.

Consejos para dibujarlo bien: la variable que se considera «explicativa» (la que se podría usar para predecir) va en el eje X; cada eje lleva su escala, que no tiene por qué empezar en 0; y siempre se indican los nombres de las variables con sus unidades. Las hojas de cálculo lo dibujan automáticamente con el gráfico de tipo dispersión.



12.4 Tipos de correlación

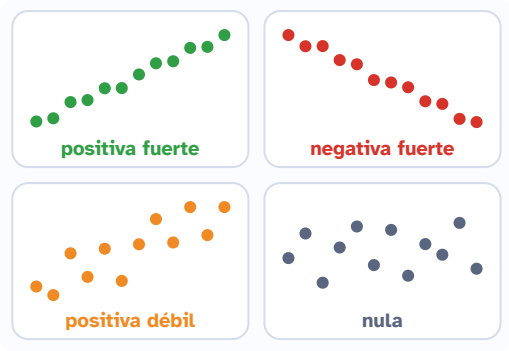
La **correlación** es el grado de relación entre las dos variables. Según la forma de la nube se distinguen:

- **Correlación positiva** (directa): al aumentar X, tiende a aumentar Y. La nube sube. Ejemplo: temperatura y venta de helados.
- **Correlación negativa** (inversa): al aumentar X, tiende a disminuir Y. La nube baja. Ejemplo: antigüedad de un coche y su precio.
- **Correlación nula** (incorrelación): no se aprecia ninguna tendencia. Ejemplo: altura de una persona y su nota de matemáticas.

Además, según lo agrupados que estén los puntos:

- Correlación **fuerte**: los puntos están muy cerca de una línea.
- Correlación **débil**: hay tendencia, pero con mucha dispersión.

Y según la forma, la correlación puede ser **lineal** (los puntos siguen una recta) o **no lineal** (siguen una curva, como una parábola o una exponencial). En este curso estudiamos solo la correlación lineal. Ojo: una nube con forma de U tiene una relación clara, pero no lineal, y las medidas de este tema darán una correlación cercana a cero. Por eso siempre hay que mirar el dibujo antes de calcular.



12.5 El centro de gravedad de la nube

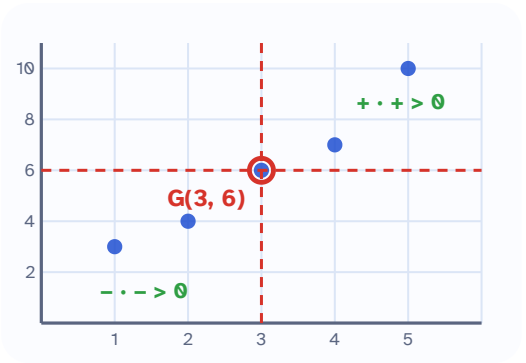
Para medir numéricamente la correlación, necesitamos primero un punto de referencia: el **centro de gravedad** de la nube, que es el punto cuyas coordenadas son las medias de cada variable:

$$G = (\bar{x}, \bar{y}) \quad \bar{x} = \Sigma x_i / n \quad \bar{y} = \Sigma y_i / n$$

En el ejemplo de las horas de estudio: $\bar{x} = (1 + 2 + 3 + 4 + 5)/5 = 3$ horas e $\bar{y} = (3 + 4 + 6 + 7 + 10)/5 = 6$ puntos. El centro de gravedad es **G(3, 6)**.

Si por G trazamos una recta vertical y otra horizontal, la nube queda dividida en cuatro cuadrantes. En una correlación positiva, la mayoría de los puntos caen en el cuadrante superior derecho (x e y por encima de su media) y en el inferior izquierdo (ambas por debajo). En una correlación negativa, la mayoría están en los otros dos cuadrantes. Si están repartidos por igual, la correlación es nula.

Esta idea es la base de la covarianza, la medida que veremos a continuación. Además, el centro de gravedad tiene una propiedad muy útil: la recta de regresión, la que mejor se ajusta a la nube, **siempre pasa por G**. Por eso es lo primero que se calcula en cualquier análisis.


10
8
6
4
2
1
2
3
4
5
G(3, 6)
− · − > 0
+ · + > 0

12.6 La covarianza

La **covarianza** mide hacia dónde va la relación entre X e Y. Se calcula multiplicando, para cada individuo, cuánto se separa de la media en X y cuánto en Y, y haciendo la media de esos productos:

$$S_{xy} = \Sigma\,(x_i - \bar{x})(y_i - \bar{y}) / n = (\Sigma\, x_i\, y_i) / n - \bar{x}\cdot\bar{y}$$

La segunda fórmula es equivalente y suele ser más cómoda. Si un punto está en el cuadrante superior derecho o en el inferior izquierdo respecto de G, su producto es positivo; si está en los otros dos, negativo. Por tanto:

- $S_{xy} > 0$ → correlación positiva.
- $S_{xy} < 0$ → correlación negativa.
- $S_{xy} \approx 0$ → no hay correlación lineal.

En el ejemplo: $\Sigma x_i y_i = 1\cdot3 + 2\cdot4 + 3\cdot6 + 4\cdot7 + 5\cdot10 = 3 + 8 + 18 + 28 + 50 = 107$. $S_{xy} = 107/5 - 3 \cdot 6 = 21{,}4 - 18 = \mathbf{3{,}4}$. Es positiva, como se veía en la nube.

La covarianza tiene un inconveniente: su valor depende de las **unidades**. Si midiéramos el tiempo en minutos en vez de horas, la covarianza se multiplicaría por 60, aunque la relación sea la misma. Por eso su signo es muy útil, pero su tamaño no dice si la correlación es fuerte o débil.

Covarianza del ejemplo

$\Sigma\, x_i y_i = 3 + 8 + 18 + 28 + 50 = 107$

$S_{xy} = 107/5 - 3 \cdot 6$

$S_{xy} = 21{,}4 - 18 = 3{,}4 > 0$

el signo indica correlación positiva

12.7 El coeficiente de correlación lineal

Para tener una medida que no dependa de las unidades, se divide la covarianza entre el producto de las **desviaciones típicas** de X y de Y. Se obtiene el **coeficiente de correlación lineal de Pearson**:

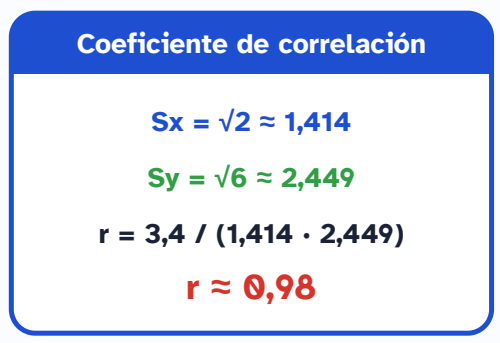
$$r = S_{xy} / (S_x \cdot S_y)$$

Recuerda que la desviación típica es $S_x = \sqrt{(\Sigma x_i^2/n - \bar{x}^2)}$.

En el ejemplo: $\Sigma x_i^2 = 1 + 4 + 9 + 16 + 25 = 55$, así que $S_x^2 = 55/5 - 9 = 2$ y $S_x = \sqrt{2} \approx 1{,}414$. $\Sigma y_i^2 = 9 + 16 + 36 + 49 + 100 = 210$, $S_y^2 = 210/5 - 36 = 6$ y $S_y = \sqrt{6} \approx 2{,}449$. Por tanto:

$$r = 3{,}4 / (1{,}414 \cdot 2{,}449) \approx 3{,}4 / 3{,}464 \approx 0{,}98$$

El coeficiente r tiene propiedades muy útiles: siempre está entre –1 y 1, tiene el mismo signo que la covarianza y no cambia si se cambian las unidades de medida. Lo inventó a finales del siglo XIX el matemático británico Karl Pearson, a partir de las ideas de Francis Galton, que estudiaba la relación entre la altura de padres e hijos.



12.8 Interpretar el coeficiente de correlación

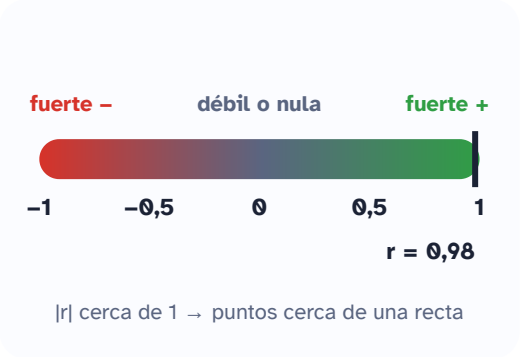
El valor de r resume en un número el tipo y la fuerza de la correlación lineal:

- **r = 1**: dependencia funcional lineal creciente. Todos los puntos están sobre una recta que sube.
- **r = –1**: dependencia funcional lineal decreciente. Todos sobre una recta que baja.
- **r cercano a 1 o a –1** ($|r| > 0{,}8$ aproximadamente): correlación **fuerte**.
- **|r| entre 0,5 y 0,8**: correlación **moderada**.
- **|r| menor que 0,5**: correlación **débil**.
- **r ≈ 0**: no hay correlación lineal.

Estos límites son orientativos y dependen del campo: en física se esperan correlaciones de 0,99, mientras que en psicología o sociología un r = 0,5 ya puede ser un hallazgo interesante.

En el ejemplo de las horas de estudio, r ≈ 0,98: correlación positiva muy fuerte. En el de los coches (antigüedad y precio), un cálculo similar da r ≈ −0,99: negativa muy fuerte.

Hay que recordar dos advertencias. Primera: r solo mide relación **lineal**; una relación curva perfecta puede dar r ≈ 0. Segunda: con muy pocos datos, un r alto puede deberse a la casualidad; cuantos más datos, más fiable es la conclusión. Un solo dato extremo (atípico) también puede alterar mucho el valor de r.



|r| cerca de 1 → puntos cerca de una recta

12.9 La recta de regresión

Cuando la correlación es fuerte, tiene sentido buscar la recta que **mejor se ajusta** a la nube de puntos. Se llama **recta de regresión de Y sobre X** y se usa para estimar Y a partir de X. Pasa por el centro de gravedad G($\bar{x}$; $\bar{y}$) y su pendiente es el cociente entre la covarianza y la varianza de X:

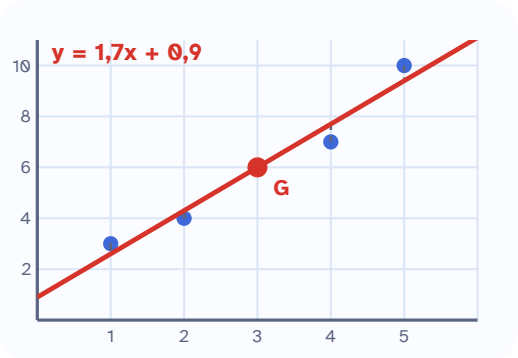
$$y - \bar{y} = (Sxy / Sx^2) \cdot (x - \bar{x})$$

El número Sxy/Sx^2 se llama **coeficiente de regresión**; tiene el mismo signo que la covarianza.

En el ejemplo: pendiente = 3,4 / 2 = 1,7. La recta es y − 6 = 1,7(x − 3), es decir, y = 1,7x + 0,9. Interpretación: por cada hora más de estudio a la semana, la nota aumenta de media 1,7 puntos.

¿Por qué es la «mejor» recta? Para cada punto de la nube, se mide la distancia vertical hasta la recta (el error o **residuo**). La recta de regresión es la que hace

mínima la suma de los cuadrados de esos errores. Por eso el método se llama de **mínimos cuadrados**, y lo desarrollaron Legendre y Gauss a principios del siglo XIX para calcular las órbitas de los planetas y cometas a partir de observaciones con errores.



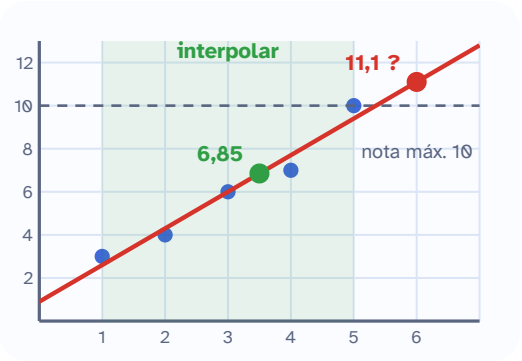
12.10 Hacer estimaciones y valorar su fiabilidad

La utilidad práctica de la recta de regresión es **estimar** el valor de Y para un valor de X del que no tenemos datos. Basta sustituir en la ecuación. En el ejemplo, un alumno que estudie 3,5 horas semanales sacaría, según el modelo, $y = 1{,}7 \cdot 3{,}5 + 0{,}9 \approx$ **6,85**.

¿Cuánto podemos fiarnos de esa estimación? Depende de dos cosas:

1. **Del valor de r**. Si |r| está cerca de 1, los puntos están muy pegados a la recta y la estimación será buena. Si |r| es pequeño, la estimación es poco fiable, porque los datos reales se separan mucho de la recta.
2. **De dónde esté el valor de x**. Estimar dentro del intervalo de los datos (**interpolar**) es razonable. Estimar fuera de él (**extrapolar**) es arriesgado, porque no sabemos si la tendencia se mantiene.

Un ejemplo de lo absurda que puede ser la extrapolación: con nuestra recta, un alumno que estudie 6 horas sacaría $y = 1{,}7 \cdot 6 + 0{,}9 = 11{,}1$, una nota imposible. Y uno que estudie 20 horas, ¡35! La relación entre estudio y nota no puede seguir siendo lineal indefinidamente. Del mismo modo, un niño crece unos 6 cm al año entre los 4 y los 10 años, pero sería absurdo usar esa tendencia para predecir su altura a los 40.

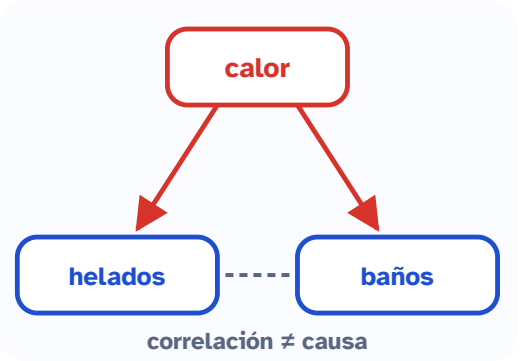


12.11 Correlación no implica causalidad

Este es probablemente el aviso más importante de toda la estadística: que dos variables estén correlacionadas no demuestra que una cause la otra. Hay varias explicaciones posibles para una correlación:

- **Causalidad directa**: X provoca Y. Estudiar más mejora la nota; fumar aumenta el riesgo de cáncer.
- **Una tercera variable** que influye en las dos. En verano aumentan a la vez las ventas de helados y los ahogamientos en playas, pero los helados no provocan ahogamientos: la causa común es el calor, que hace que más gente coma helados y se bañe.
- **Causalidad inversa**: es Y la que provoca X. Se observa que en los barrios con más policías hay más delitos; no es que la policía cause delitos, sino que se envían más agentes donde hay más delincuencia.
- **Pura casualidad**. Hay webs que recopilan correlaciones absurdas, como el número de películas de un actor y el de personas que se ahogan en piscinas en un año, con coeficientes altísimos que no significan nada.

Para demostrar una relación causa-efecto hacen falta **experimentos controlados**, en los que se cambia una sola variable y se mantienen las demás, o muchos estudios coincidentes que descarten las otras explicaciones. Ante una noticia del tipo «los que hacen X viven más», pregunta siempre: ¿no habrá otra variable detrás?



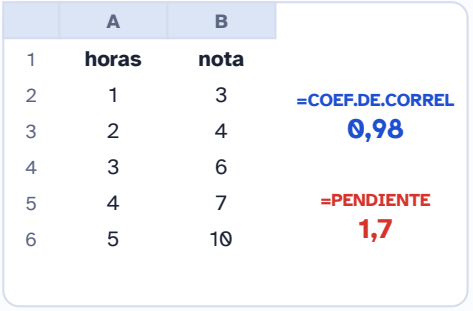
12.12 Calculadora y hoja de cálculo

Con muchos datos, los cálculos a mano son largos y es fácil equivocarse. Las herramientas digitales los hacen en segundos.

Con la calculadora científica: se entra en el modo estadístico (STAT o MODE) y se elige el tipo de regresión lineal, normalmente indicado como **A + BX**. Se introducen los pares de datos en dos columnas y, desde el menú de resultados, se obtienen $\bar{x}$, $\bar{y}$, Sx (σx), Sy (σy), el coeficiente r y los coeficientes A (ordenada) y B (pendiente) de la recta de regresión. Algunas calculadoras incluso estiman $\hat{y}$ para un x dado.

Con una hoja de cálculo: con los valores de X en la columna A y los de Y en la B, se usan funciones como `=PROMEDIO()`, `=COEF.DE.CORREL(A2:A6;B2:B6)`, `=PENDIENTE(B2:B6;A2:A6)` e `=INTERSECCION.EJE(B2:B6;A2:A6)`. Además, al crear un gráfico de dispersión se puede añadir una «línea de tendencia» lineal y pedir que muestre su ecuación y el valor de R^2, que es el cuadrado de r.

Atención: la calculadora siempre da un resultado, aunque no tenga sentido. Por eso, antes de usar la recta, hay que **dibujar la nube** y comprobar que la relación es lineal, y después interpretar el resultado en el contexto.



12.13 Un estudio completo paso a paso

Una heladería anota durante cinco días la temperatura máxima (X, en °C) y las tarrinas vendidas (Y):

X (°C)	10	15	20	25	30
Y (tarrinas)	12	20	31	42	50

1. **Nube**: los puntos suben y están casi alineados.
2. **Medias**: $\bar{x} = 20$ °C, $\bar{y} = 155/5 = 31$ tarrinas. G(20, 31).
3. **Desviaciones típicas**: $S_x^2 = 2250/5 - 400 = 50$, $S_x \approx 7{,}07$. $S_y^2 = 5769/5 - 961 = 192{,}8$, $S_y \approx 13{,}89$.
4. **Covarianza**: $\Sigma xy = 3590$; $S_{xy} = 3590/5 - 20 \cdot 31 = 718 - 620 = 98$.
5. **Correlación**: $r = 98/(7{,}07 \cdot 13{,}89) \approx 0{,}998$: positiva y casi perfecta.
6. **Recta**: pendiente $98/50 = 1{,}96$. $y - 31 = 1{,}96(x - 20)$ → **$y = 1{,}96x - 8{,}2$**. Cada grado más supone unas 2 tarrinas más.
7. **Estimación**: para 22 °C, $y \approx 1{,}96 \cdot 22 - 8{,}2 \approx 35$ tarrinas. Es fiable: r alto e interpolación.

Para 40 °C, la recta daría unas 70 tarrinas, pero es una extrapolación: con tanto calor quizá la gente no salga a la calle. Y para 0 °C daría −8,2 tarrinas, un resultado imposible que confirma que el modelo solo vale **dentro del rango** de los datos.



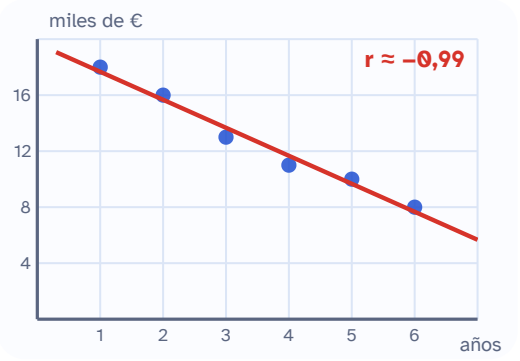
12.14 La estadística bidimensional en la vida real

El análisis de dos variables está detrás de muchas decisiones que nos afectan:

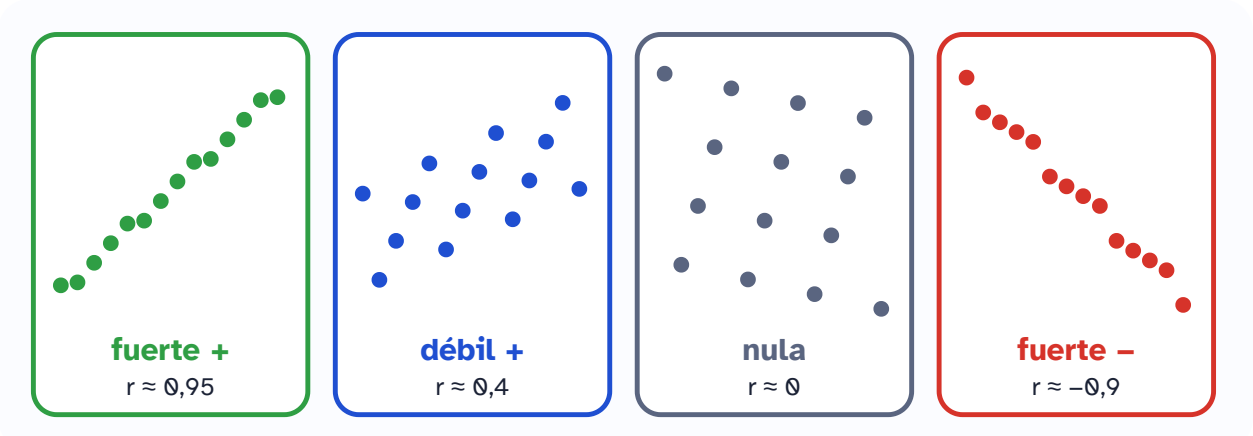
- **Economía y empresas**: relacionar la inversión en publicidad con las ventas, el precio de un producto con la demanda, o los metros cuadrados de un piso con su precio de alquiler. Los portales inmobiliarios estiman el valor de una vivienda con regresiones de este tipo (con muchas más variables).

- **Medicina y salud**: estudiar la relación entre la dosis de un medicamento y su efecto, entre el ejercicio físico y la tensión arterial, o entre la edad y la densidad ósea.
- **Ciencias de la Tierra**: la relación entre la concentración de CO_2 en la atmósfera y la temperatura media del planeta se estudia con series de datos de décadas.
- **Deporte**: los analistas relacionan la distancia recorrida, los tiros o la posesión con los resultados para diseñar estrategias.
- **Inteligencia artificial**: la regresión lineal es uno de los primeros algoritmos de «aprendizaje automático»: el ordenador «aprende» la recta a partir de los datos y luego predice.

En todos los casos, el método es el mismo que has aprendido: datos fiables, nube de puntos, coeficiente de correlación, recta de regresión y una interpretación crítica que tenga en cuenta las limitaciones del modelo.



Cómo leer una nube de puntos



Ejercicios

1. **Indica en cada caso si esperas correlación positiva, negativa o nula: (a) horas de entrenamiento y tiempo en una carrera; (b) número de hermanos y número de calzado; (c) superficie de un piso y su precio.**

2. **Representa la nube de puntos de X: 1, 2, 3, 4, 5 e Y: 10, 8, 7, 4, 1 y describe la correlación.**

3. **Calcula el centro de gravedad de X: 1, 2, 3, 4, 5 e Y: 10, 8, 7, 4, 1.**

4. **Para los datos anteriores, sabiendo que Σxy = 68, calcula la covarianza.**

5. **Ordena de más débil a más fuerte estas correlaciones: r = 0,6; r = −0,9; r = 0,1; r = −0,4.**

6. **¿Qué significa que r = −1? ¿Y r = 0,05?**

7. **La recta de regresión de la nota (Y) sobre las horas de estudio (X) de un grupo es y = 1,2x + 3. Estima la nota de quien estudia 4 horas e interpreta la pendiente.**

8. **¿Puede la covarianza ser positiva y el coeficiente de correlación negativo? Razona.**

9. **Explica con un ejemplo la diferencia entre dependencia funcional y dependencia estadística.**

10. **En una ciudad se observa que los días con más paraguas abiertos hay más accidentes de tráfico. ¿Los paraguas provocan accidentes?**

11. **Calcula Sx para X: 2, 4, 6, 8 (usa $\Sigma x^2 = 120$).**

12. **Un modelo predice el peso (kg) a partir de la altura (cm) con y = 0,84x – 78,4, obtenido con personas de 150 a 170 cm. Estima el peso de alguien de 162 cm.**

13. **Calcula el coeficiente de correlación de X: 1, 2, 3, 4, 5 e Y: 10, 8, 7, 4, 1 ($\Sigma x^2 = 55$, $\Sigma y^2 = 230$, $\Sigma xy = 68$).**

14. **Halla la recta de regresión de Y sobre X para los datos anteriores y estima Y para x = 2,5.**

15. **Con X: 1, 3, 5, 7, 9 e Y: 2, 6, 5, 9, 8, calcula $\bar{x}$, $\bar{y}$, Sxy y r.**

16. **Para los datos anteriores, halla la recta de regresión y estima Y para x = 6. ¿Es muy fiable?**

17. **Una empresa relaciona los euros invertidos en publicidad (X, en miles) con las ventas (Y, en miles): la recta es y = 4,5x + 20 con r = 0,92. ¿Cuánto vendería invirtiendo 8.000 €? Si los datos van de 2.000 a 10.000 €, ¿se puede estimar para 50.000 €?**

18. **Si a todos los valores de X se les suma 10, ¿cómo cambian $\bar{x}$, Sx, Sxy y r?**

19. **Si la estatura se mide en metros en vez de en centímetros, ¿qué ocurre con la covarianza entre estatura y peso? ¿Y con r?**

20. **Con X: 0, 1, 2, 3, 4 e Y: 4, 3, 4, 5, 4, calcula r e interprétalo.**

21. **Dibuja una nube de puntos con forma de U (por ejemplo, los puntos (–2, 4), (–1, 1), (0, 0), (1, 1), (2, 4)) y calcula su covarianza. ¿Qué concluyes?**

22. **En una clase, r = 0,7 entre la nota de Matemáticas y la de Física. Un alumno dice: «Como r no es 1, no hay relación». ¿Tiene razón?**

23. **Calcula la recta de regresión para la temperatura (10, 15, 20, 25, 30 °C) y las tarrinas (12, 20, 31, 42, 50), sabiendo que $S_{xy} = 98$ y $S_x^2 = 50$, y estima las ventas a 18 °C.**

24. **Explica qué es un residuo en la recta de regresión y calcula el del punto (5, 10) con la recta $y = 1{,}7x + 0{,}9$.**

25. **Demuestra que $\Sigma(x_i - \bar{x})(y_i - \bar{y})/n = \Sigma x_i y_i/n - \bar{x}\bar{y}$.**

26. **Para unos datos se sabe que $\bar{x} = 4$, $\bar{y} = 10$, $S_x = 2$, $S_y = 5$ y $r = 0{,}8$. Halla la recta de regresión de Y sobre X.**

27. **Para los datos de las horas de estudio (X: 1, 2, 3, 4, 5; Y: 3, 4, 6, 7, 10), calcula todos los residuos con la recta $y = 1{,}7x + 0{,}9$ y comprueba que suman 0.**

28. **Se añade a los datos de las horas de estudio un sexto alumno con 5 horas y nota 2 (quizá estuvo enfermo). ¿Cómo crees que cambiará r? Calcúlalo.**

29. **La recta de regresión de Y sobre X es $y = 3x - 2$ y $\bar{x} = 5$. ¿Cuánto vale $\bar{y}$? Si $S_x = 2$ y $S_y = 7$, ¿cuánto vale r?**

30. **La recta de regresión de Y sobre X es $y = -0{,}5x + 12$ y el coeficiente de correlación es $r = -0{,}6$. Un compañero afirma que, como la pendiente es pequeña, la correlación tiene que ser débil. ¿Tiene razón?**

31. **Comprueba que la pendiente de la recta de regresión es $r \cdot S_y/S_x$ y úsalo con los datos de las horas de estudio ($r \approx 0{,}9815$, $S_x = \sqrt{2}$, $S_y = \sqrt{6}$).**

32. **En una tabla de doble entrada, 4 alumnos tienen (1 hermano, 0 mascotas), 6 tienen (1, 1), 2 tienen (2, 1) y 8 tienen (2, 2). Calcula $\bar{x}$, $\bar{y}$ y la covarianza teniendo en cuenta las frecuencias.**

33. **Busca un ejemplo de correlación entre dos variables en una noticia y analiza si la conclusión que se saca es causal. Propón una tercera variable que podría explicarla.**

34. **Para datos con X: 1, 2, 3, 4, 5, 6 (antigüedad de coches) e Y: 18, 16, 13, 11, 10, 8 (miles de €) se obtiene $S_{xy} \approx -5{,}83$ y $S_x^2 \approx 2{,}92$. Halla la recta y estima a qué edad el modelo daría un precio de 5.000 €. ¿Es fiable?**

Practica

1. **Una variable bidimensional estudia...**

   A) una característica
   B) dos características de cada individuo
   C) dos poblaciones
   D) una variable dos veces

2. **El diagrama de dispersión representa...**

   A) barras de frecuencias
   B) una recta
   C) un sector circular
   D) cada par como un punto

3. **Si al aumentar X tiende a disminuir Y, la correlación es...**

   A) negativa
   B) positiva
   C) nula
   D) funcional

4. **El centro de gravedad de la nube es...**

   A) $(0, 0)$
   B) (S_x, S_y)
   C) $(\bar{x}, \bar{y})$
   D) el punto más alto

5. **Si la covarianza es negativa, la correlación es...**

   A) positiva
   B) negativa
   C) nula
   D) fuerte

6. **S_{xy} =**

   A) $S_x \cdot S_y$
   B) $\Sigma xy - x\bar{y}$
   C) $\Sigma x \cdot \Sigma y / n$
   D) $\Sigma xy / n - x\bar{y}$

7. **El coeficiente de correlación r siempre está entre...**

A) –1 y 1

B) 0 y 1

C) –∞ y +∞

D) 0 y 100

8. **r = Sxy dividido entre...**

A) Sx + Sy

B) Sx^2

C) Sx · Sy

D) n

9. **Si r = 0,95, la correlación es...**

A) positiva débil

B) positiva fuerte

C) negativa fuerte

D) nula

10. **Si r = –1...**

A) no hay relación

B) la covarianza es 0

C) la nube es redonda

D) todos los puntos están sobre una recta decreciente

11. **Si cambiamos las unidades de X, r...**

A) no cambia

B) cambia

C) se hace 0

D) cambia de signo

12. **La recta de regresión siempre pasa por...**

A) el origen

B) el primer punto

C) el centro de gravedad

D) el punto más alto

13. **La pendiente de la recta de regresión de Y sobre X es...**

A) Sxy/Sy^2

B) Sxy/Sx^2

C) r

D) Sx/Sy

14. **Estimar fuera del intervalo de los datos se llama...**

A) interpolar

B) regresar

C) correlacionar

D) extrapolar

15. **Una estimación es más fiable cuando...**

A) |r| es cercano a 1 y se interpola

B) |r| es cercano a 0

C) hay pocos datos

D) se extrapola

16. **Una correlación fuerte entre X e Y...**

A) demuestra que X causa Y

B) demuestra que Y causa X

C) no demuestra causalidad

D) es imposible

17. **Las ventas de helados y los ahogamientos están correlacionados por...**

A) casualidad pura

B) una tercera variable: el calor

C) causalidad directa

D) error de cálculo

18. **Una nube con forma de U perfecta tiene r...**

A) cercano a 1

B) cercano a –1

C) igual a 2

D) cercano a 0

19. **En la hoja de cálculo, el coeficiente r se calcula con...**

A) =COEF.DE.CORREL

B) =PROMEDIO

C) =SUMA

D) =MODA

20. **El método para obtener la recta de regresión se llama...**

A) de reducción

B) de Ruffini

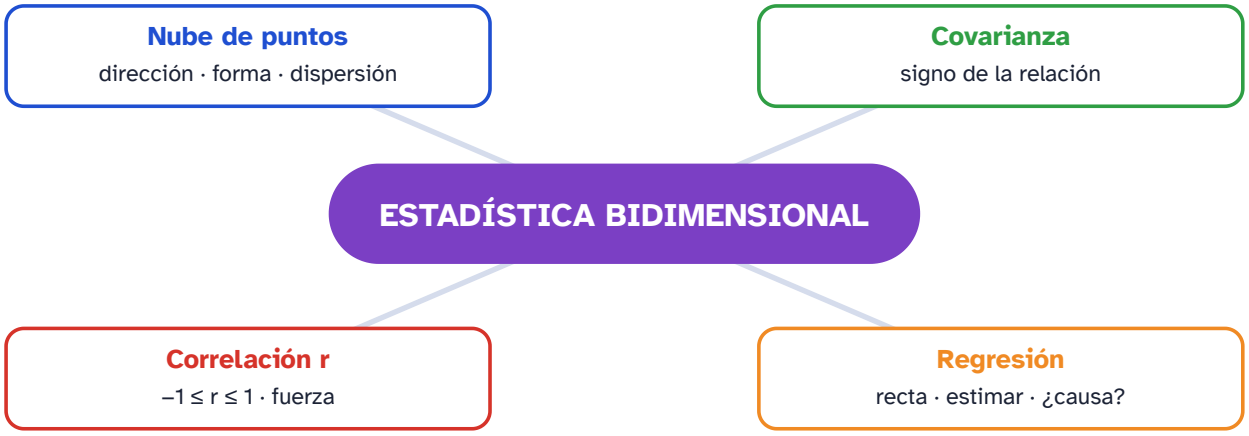
C) de mínimos cuadrados

D) de Laplace

Explícalo con tus palabras

Incluye: Qué es una variable bidimensional y cómo se representa; Cómo se reconoce en una nube si la correlación es positiva, negativa o nula; Qué indica el signo de la covarianza y por qué no basta su tamaño; Qué mide el coeficiente de correlación y cómo se interpreta; Por qué correlación no implica causalidad.

Resumen



Glosario

Variable bidimensional	Par de variables (X, Y) observadas en cada individuo.
Diagrama de dispersión	Representación de cada par como un punto; nube de puntos.
Dependencia funcional	Relación exacta: cada x determina y.
Dependencia estadística	Relación con tendencia pero con variaciones; correlación.
Correlación positiva	Al aumentar X tiende a aumentar Y.
Correlación negativa	Al aumentar X tiende a disminuir Y.
Centro de gravedad	Punto $(\bar{x}, \bar{y})$.
Covarianza	$S_{xy} = \Sigma xy/n - \bar{x}\bar{y}$; su signo indica el sentido de la correlación.
Coeficiente de correlación	$r = S_{xy}/(S_x \cdot S_y)$; entre −1 y 1.
Recta de regresión	Recta que mejor se ajusta a la nube: $y - \bar{y} = (S_{xy}/S_x^2)(x - \bar{x})$.
Coeficiente de regresión	Pendiente de la recta de regresión, S_{xy}/S_x^2.
Residuo	Diferencia entre el valor real y el estimado por la recta.
Interpolar	Estimar dentro del intervalo de los datos.
Extrapolar	Estimar fuera del intervalo de los datos.

Dato atípico	Valor muy alejado del resto que puede alterar los resultados.
Causalidad	Relación en la que una variable provoca cambios en la otra.

Tarjetas de repaso

Recórtalas: pregunta delante, respuesta detrás.

Variable bidimensional

Dos características (X, Y) de cada individuo.

Nube de puntos

Cada par (x_i, y_i) dibujado como un punto.

Centro de gravedad

$G = (\bar{x}, \bar{y})$

Covarianza

$Sxy = \Sigma x_i y_i / n - \bar{x} \cdot \bar{y}$

Signo de Sxy

Positivo: nube que sube; negativo: nube que baja.

Coeficiente de correlación

$r = Sxy/(Sx \cdot Sy)$

Valores de r

Entre -1 y 1; cerca de ± 1, fuerte; cerca de 0, débil.

Recta de regresión

$y - \bar{y} = (Sxy/Sx^2)(x - \bar{x})$

Interpolar

Estimar dentro del rango de datos: fiable si $|r|$ es alto.

Extrapolar

Estimar fuera del rango: arriesgado.

Correlación y causa

Correlación no implica causalidad.

r = 0

No hay relación lineal (puede haberla no lineal).

Soluciones

1. **B)** Pares (x_i, y_i).
2. **D)** Nube de puntos.
3. **A)** La nube baja.
4. **C)** Medias de cada variable.
5. **B)** Mismo signo.
6. **D)** Fórmula abreviada.
7. **A)** Propiedad de r.
8. **C)** Producto de desviaciones típicas.
9. **B)** |r| cerca de 1.
10. **D)** Dependencia lineal exacta.
11. **A)** No depende de las unidades.
12. **C)** Pasa por $(\bar{x}, \bar{y})$.
13. **B)** Coeficiente de regresión.
14. **D)** Es arriesgado.
15. **A)** Puntos cerca de la recta.
16. **C)** Correlación no implica causalidad.
17. **B)** Causa común.
18. **D)** r solo mide relación lineal.
19. **A)** Función de correlación.
20. **C)** Minimiza la suma de los cuadrados de los residuos.

Soluciones de los ejercicios

1. (a) Negativa: más entrenamiento, menos tiempo. (b) Nula. (c) Positiva.
2. Los puntos bajan casi en línea recta: correlación negativa y fuerte.
3. $\bar{x} = 15/5 = 3$; $\bar{y} = 30/5 = 6$. G(3, 6).
4. $S_{xy} = 68/5 - 3 \cdot 6 = 13{,}6 - 18 = -4{,}4$. Negativa.
5. Por $|r|$: $0{,}1 < -0{,}4 < 0{,}6 < -0{,}9$.
6. $r = -1$: todos los puntos sobre una recta decreciente (dependencia funcional lineal). $r = 0{,}05$: prácticamente no hay correlación lineal.
7. $y = 4{,}8 + 3 = 7{,}8$. Cada hora más de estudio supone de media 1,2 puntos más.
8. No: $r = S_{xy}/(S_x \cdot S_y)$ y las desviaciones típicas son positivas, así que r tiene siempre el signo de la covarianza.
9. Funcional: el área de un cuadrado depende exactamente de su lado ($A = l^2$). Estadística: el peso tiende a aumentar con la altura, pero dos personas de igual altura pueden pesar distinto.
10. No. Hay una tercera variable, la lluvia, que aumenta a la vez el uso de paraguas y los accidentes (calzada mojada, menos visibilidad).
11. $\bar{x} = 5$. $S_x^2 = 120/4 - 25 = 5$. $S_x = \sqrt{5} \approx 2{,}24$.
12. $y = 0{,}84 \cdot 162 - 78{,}4 = 136{,}08 - 78{,}4 \approx 57{,}7$ kg.
13. $S_x^2 = 11 - 9 = 2$, $S_x \approx 1{,}414$. $S_y^2 = 46 - 36 = 10$, $S_y \approx 3{,}162$. $S_{xy} = -4{,}4$. $r = -4{,}4/(1{,}414 \cdot 3{,}162) \approx -0{,}98$.
14. Pendiente $= -4{,}4/2 = -2{,}2$. $y - 6 = -2{,}2(x - 3) \rightarrow y = -2{,}2x + 12{,}6$. Para $x = 2{,}5$: $y = -5{,}5 + 12{,}6 = 7{,}1$.
15. $\bar{x} = 5$, $\bar{y} = 6$. $\Sigma xy = 2 + 18 + 25 + 63 + 72 = 180$; $S_{xy} = 36 - 30 = 6$. $\Sigma x^2 = 165 \rightarrow S_x^2 = 33 - 25 = 8$; $\Sigma y^2 = 210 \rightarrow S_y^2 = 42 - 36 = 6$. $r = 6/(\sqrt{8} \cdot \sqrt{6}) \approx 6/6{,}93 \approx 0{,}87$.
16. Pendiente $6/8 = 0{,}75$. $y - 6 = 0{,}75(x - 5) \rightarrow y = 0{,}75x + 2{,}25$. Para $x = 6$: 6,75. Es razonable (interpolación, $r \approx 0{,}87$), aunque menos fiable que con $r \approx 0{,}99$.
17. $y = 4{,}5 \cdot 8 + 20 = 56 \rightarrow 56.000$ €. Para 50.000 € sería una extrapolación muy lejana: no es fiable (el efecto de la publicidad suele saturarse).
18. $\bar{x}$ aumenta 10; S_x no cambia (las distancias a la media son las mismas); S_{xy} tampoco; r tampoco.
19. Los valores de X se dividen entre 100, así que S_{xy} se divide entre 100. S_x también se divide entre 100, de modo que r no cambia.
20. $\bar{x} = 2$, $\bar{y} = 4$. $\Sigma xy = 0 + 3 + 8 + 15 + 16 = 42$, $S_{xy} = 8{,}4 - 8 = 0{,}4$. $S_x^2 = 2$; $S_y^2 = (16 + 9 + 16 + 25 + 16)/5 - 16 = 0{,}4$. $r = 0{,}4/(\sqrt{2} \cdot \sqrt{0{,}4}) \approx 0{,}45$: correlación positiva débil.
21. $\bar{x} = 0$, $\bar{y} = 2$. $\Sigma xy = -8 - 1 + 0 + 1 + 8 = 0$. $S_{xy} = 0 - 0 = 0$, así que $r = 0$. Pero hay una relación perfecta, $y = x^2$, no lineal: $r = 0$ no significa ausencia de relación.
22. No. $r = 0{,}7$ indica una correlación positiva moderada-fuerte: hay relación, aunque no perfecta (influyen otros factores).
23. Pendiente 1,96; $y - 31 = 1{,}96(x - 20) \rightarrow y = 1{,}96x - 8{,}2$. A 18 °C: $35{,}28 - 8{,}2 \approx 27$ tarrinas.

24. Es la diferencia entre el valor real y el estimado: 10 – (1,7 · 5 + 0,9) = 10 – 9,4 = 0,6. El punto queda 0,6 por encima de la recta.
25. Desarrollando: $\Sigma(x_i y_i - x_i\bar{y} - x\bar{y}_i + x\bar{y})/n = \Sigma x_i y_i/n - \bar{y}\,\Sigma x_i/n - \bar{x}\Sigma y_i/n + x\bar{y} = \Sigma x_i y_i/n - \bar{y}\bar{x} - x\bar{y} + x\bar{y} = \Sigma x_i y_i/n - x\bar{y}$.
26. $Sxy = r \cdot Sx \cdot Sy = 0{,}8 \cdot 2 \cdot 5 = 8$. Pendiente = 8/4 = 2. $y - 10 = 2(x - 4) \rightarrow y = 2x + 2$.
27. Estimados: 2,6; 4,3; 6; 7,7; 9,4. Residuos: 0,4; –0,3; 0; –0,7; 0,6. Suma: 0,4 – 0,3 + 0 – 0,7 + 0,6 = 0. La recta de regresión siempre «equilibra» los errores.
28. Debería bajar mucho. Datos X: 1, 2, 3, 4, 5, 5; Y: 3, 4, 6, 7, 10, 2. $\bar{x} = 20/6 \approx 3{,}33$; $\bar{y} = 32/6 \approx 5{,}33$. $\Sigma xy = 117$; $Sxy = 19{,}5 - 17{,}78 \approx 1{,}72$. $\Sigma x^2 = 80 \rightarrow Sx^2 \approx 13{,}33 - 11{,}11 = 2{,}22$; $\Sigma y^2 = 214 \rightarrow Sy^2 \approx 35{,}67 - 28{,}44 = 7{,}22$. $r \approx 1{,}72/(1{,}49 \cdot 2{,}69) \approx 0{,}43$. Un solo dato atípico hace caer r de 0,98 a 0,43.
29. La recta pasa por G: $\bar{y} = 15 - 2 = 13$. Pendiente = $Sxy/Sx^2 \rightarrow Sxy = 3 \cdot 4 = 12$. $r = 12/(2 \cdot 7) \approx 0{,}857$.
30. No. La pendiente depende de las unidades y de las desviaciones típicas (pendiente = $r \cdot Sy/Sx$), mientras que r no. Aquí $|r| = 0{,}6$ indica correlación moderada, independientemente del valor de la pendiente.
31. $Sxy/Sx^2 = (r \cdot Sx \cdot Sy)/Sx^2 = r \cdot Sy/Sx$. Con los datos: $0{,}9815 \cdot \sqrt{6}/\sqrt{2} = 0{,}9815 \cdot \sqrt{3} \approx 0{,}9815 \cdot 1{,}732 \approx 1{,}70$, que coincide con 3,4/2 = 1,7.
32. n = 20. $\bar{x} = (1 \cdot 10 + 2 \cdot 10)/20 = 1{,}5$. $\bar{y} = (0 \cdot 4 + 1 \cdot 8 + 2 \cdot 8)/20 = 24/20 = 1{,}2$. $\Sigma f \cdot x \cdot y = 4 \cdot 0 + 6 \cdot 1 + 2 \cdot 2 + 8 \cdot 4 = 42$. $Sxy = 42/20 - 1{,}5 \cdot 1{,}2 = 2{,}1 - 1{,}8 = 0{,}3 > 0$: ligera correlación positiva.
33. Respuesta abierta. Ejemplo: «los países que consumen más chocolate tienen más premios Nobel». La causa probable no es el chocolate, sino la riqueza del país, que aumenta a la vez el consumo de chocolate y la inversión en investigación.
34. Pendiente $\approx -5{,}83/2{,}92 \approx -2$. $\bar{y} = 76/6 \approx 12{,}67$; $\bar{x} = 3{,}5$. $y - 12{,}67 = -2(x - 3{,}5) \rightarrow y = -2x + 19{,}67$. $5 = -2x + 19{,}67 \rightarrow x \approx 7{,}3$ años. Es una extrapolación ligera (fuera de 1-6 años): orientativa, no del todo fiable.